

端侧大模型与多模态终端计算研究更新

研究口径与核心判断

这份更新以你给出的 2025 年旧材料为基底，但判断口径已经明显前移到 **2025 年下半年—2026 年上半年**：我优先采用官方技术报告、开发者文档、芯片厂商页面、研究论文、开发者大会材料，以及少量高可信媒体补充。整体结论是：“端侧计算”在 2026 年已经从“模型压缩+离线隐私”的单点叙事，升级为“端侧原生模型家族 + 端云协同路由 + Agent 化执行 + NPU/runtime 生态 + 低成本本地推理”的系统工程。旧材料中的三条核心判断——模型会继续缩小并增强、量化/加速持续推进、必须与芯片厂商和开发者共建生态——都仍然成立，但需要被大幅扩展：今天真正决定竞争力的，不再只是“能不能在手机上跑 7B”，而是 **TTFT、KV Cache 管理、工具调用、系统级 API、跨设备上下文、隐私架构、以及厂商自有 runtime 与 NPU 的协同效率**。¹

如果把 2026 年端侧大模型行业压缩成一句话，那就是：**端侧模型的主流规模并没有简单从 3B/7B 线性抬升，而是分化成了“1B 以下到 4B 左右的高效率 dense/有效参数模型”“8B 左右的高能力多模态模型”“端云协同下的 agentic orchestration”三条并行路线**。Apple 公开的 on-device model 仍然是约 3B 参数；Google 则把重点放在 Gemma 3/3n/4 的多规格边缘家族与 AI Core/LiteRT-LM；微软与 Copilot+ PC 阵营把 40+ TOPS NPU 作为最低门槛；MediaTek、Qualcomm、Intel、AMD 都把“本地 AI”的叙事从 demo 推到了量产平台层面。²

技术趋势

端侧模型能力与规模。到 2026 年，端侧模型不再是“只有 3B/7B 文本模型”这一种形态。公开可见的主流家族包括：Apple 的约 3B on-device foundation model；Google Gemma 3 的 1B/4B/12B/27B；Gemma 4 的 E2B/E4B 边缘规格；Phi-4 mini / multimodal；SmolLM3-3B；Minstral 3 的 3B/8B/14B；Qwen3 家族与 Qwen3-VL/Qwen3-Omni 的 edge-to-cloud 方案；MiniCPM-V 4.5 这种面向移动/Pad 的高效多模态模型。更重要的是，“端侧模型能力提升”的主路径已从单纯堆参数，转向“**有效参数 footprint 优化 + 多模态输入 + reasoning / non-thinking 双模式 + 工具调用**”。Qwen3 明确把“Thinking / Non-Thinking”做成官方双模式；Gemma 3/3n/4 将图像、视频、音频输入纳入边缘家族；Phi-4-multimodal 把文本、图像、音频统一到 128K 上下文；Apple 2025 技术报告则显示其 on-device 与 server model 已同时支持图像理解、工具调用与更强 reasoning。³

从“参数量区间”看，**2026 量产端侧的甜点区间更像是 1B–4B 的高效率模型，而不是 7B 单一路线**。Google Gemma 4 专门为移动/边缘给出 E2B/E4B；Gemma 3n 官方强调可在 **2GB RAM** 级别设备上工作；Meta 系的 MobileLLM / MobileLLM-Pro 则把“1B 左右高质量 on-device LM”作为明确目标。相反，8B 以上模型在手机端依然可跑，但更多落在平板、AI PC、离线工作站、或者需要 aggressive quantization 的更高端场景。**推测上**，旧材料里把 3B/7B 视为默认终局的判断需要更新成：3B 仍是系统级基础模型的合理中心点，但**真正的产品组合会向“sub-1B 辅助模型 + 2B/4B 主模型 + 云端大模型/Agent 编排”分层**。⁴

端侧 MoE、弹性模型、Matryoshka 类思路。2026 年公开量产端里，真正大规模手机量产的“显式端侧 MoE”公开案例仍不算多，但 MoE/稀疏有效参数思想已经明显进入边缘族谱。Gemma 4 的 E2B/E4B 本质上就是以低 RAM footprint 为导向的边缘规格；Qwen3-VL 明确支持 dense 与 MoE 两套架构并宣称可从 edge 到 cloud 扩展；Qwen3-Omni 甚至直接给出 30B-A3B Thinking 这种“总量大、激活小”的全模态模型形态。Apple 2025 技术报告还披露，它在 on-device model 的训练流水线上引入了 **sparse-upcycling 到 64-expert、every-2-layer** 的做法，说明即使最终设备上跑的是压缩后的单模型，训练阶段也开始将稀疏专家作为能力/成本平衡工具。**对 Matryoshka/弹性模型的判断是**：2026 年它们在研究和开源社区很活跃，但在 OEM

官方面向消费者的公开叙事里，更多被包装成“多规格边缘 family”和“thinking 开关”，而不是直接以 Matryoshka 名义量产。⁵

数据蒸馏与模型蒸馏。这一点比 2025 旧材料更重要，而且已经从“训练技巧”升级为“产品战略工具”。最典型案例就是 DeepSeek-R1：官方论文明确给出 **671B MoE teacher / reasoning family → six dense distilled students (1.5B、7B、8B、14B、32B、70B)** 的路线，并强调 R1-Zero 使用纯 RL 起步、R1 再引入 cold-start data 与多阶段训练。到 2025 年 5 月的 R1-0528，官方又进一步把 reasoning trace 蒸馏到 Qwen3 8B Base，得到 **DeepSeek-R1-0528-Qwen3-8B**，并宣称其 AIME 2024 超过 Qwen3 8B、接近 Qwen3-235B-thinking。对终端厂商而言，这意味着：“**大模型造数据—蒸小模型—再做设备专用后训练**”已经是端侧推理模型最现实的上线路径。⁶

Apple 与 Google 的公开材料也侧面说明了这一趋势。Apple 2025 技术报告强调 continued pretraining、视觉适配、多语言、本地 LoRA adapter；Phi-4-mini-instruct 的模型卡直接写明其建立在 **synthetic data + 过滤后的公开网页数据** 之上，并经过 SFT 与 DPO；MiniCPM-V 4.5、Gemma 3/4、SmolLM3、Ministral 3 等则都把“更高质量的小模型后训练”作为卖点。可以说，**2026 年端侧模型的核心不再是“从零训练一个小模型”，而是“利用更大 teacher、自蒸馏数据、偏好对齐和有监督后训练，把小模型做出大模型手感”**。⁷

预训练与后训练。旧材料中“预训练 / 后训练会持续加强”仍然成立，但 2026 年需要更精确地写成：**SFT、DPO / preference optimization、纯 RL reasoning、hybrid thinking 后训练，已经成为小模型提升的四大支柱**。DeepSeek-R1-Zero 用纯 RL 证明 reasoning 可以无 SFT 起步；R1 再通过 cold start 与多阶段对齐解决可读性与语言混杂问题。Qwen3 则把 hybrid thinking 直接做成产品特性——复杂问题开 thinking，简单请求走 near-instant non-thinking。Phi-4-mini-instruct 的模型卡明确指出使用 SFT 与 DPO；Apple 的官方 toolkit 允许开发者训练 rank-32 LoRA adapters，使“面向 app 的后训练”第一次进入系统级一等公民。⁸

量化。这是 2026 年最值得重写的部分。旧材料说“极低 bit 量化重要”，今天应该更新为：**4-bit 仍是最广泛的开发者与开源生态主流；2-bit 已进入公开可确认的系统级量产实现；1-bit / 1.58-bit 仍主要停留在研究/实验阶段，尚未见主流手机 OEM 官方大规模量产披露**。Apple 2025 技术报告最值得重视：其 on-device model 压缩到 **2 bits-per-weight, embedding table 为 4bit, KV cache 为 8bit, 并用 QAT + 低秩适配器恢复精度**。Google 在 2026 年则进一步给 Gemma 4 提供 **官方 QAT models**，明确把量化从“社区自发优化”转成官方交付物。llama.cpp 现在原生支持 **1.5-bit、2-bit、3-bit、4-bit、5-bit、6-bit、8-bit** 多种整数方案，表明极低比特已经进入主流本地推理工具链。⁹

具体到方法层，GPTQ、AWQ、SmoothQuant、QuaRot、SpinQuant、mixed precision、per-group/per-channel 量化，2026 年仍然是开源/学术与工程界的常见基线；但**真正落到量产手机的公开证据**，最清晰的仍是 Apple 的 2bit QAT、Google LiteRT-LM/Gemma 4 的官方量化链路、以及 Android / Apple silicon / llama.cpp / MNN 这类 runtime 对 4bit 与更低比特的适配。**KV Cache 量化**方面，研究上的 KIVI 方向已经把 KV 压缩推到“必要基础设施”；工业侧更能确认的是 Apple 已在量产体系里把 KV cache 压到 **8bit**。所以从产品视角看，2026 年的量化能力图谱可以写成：**4bit 是通用量产基线，2bit 是领先厂商可验证的系统级手段，KV cache quantization 已进入公开量产体系，1.x-bit 仍偏前沿**。¹⁰

权重稀疏化 / 剪枝 / 激活稀疏。SparseGPT、Wanda 仍然是研究和工程实践里最常被提及的后训练稀疏化基线，但它们在手机量产宣传中的存在感，明显弱于量化和 MoE。更直白地说：**2026 年公开的 OEM 量产叙事里，稀疏化更多出现在训练或 server 端架构，而不是作为手机发布会主卖点**。Apple 披露的 sparse-upcycling 是一个例外，证明稀疏思路已经深入训练 pipeline；Google 与 Qualcomm/MediaTek 的公开 runtime 叙事则更偏性能 kernel、多 token 预测、NPU backend 和量化。我的判断是：**2:4 结构化稀疏、SparseGPT/Wanda、激活稀疏仍非常重要，但它们在手机量产里的角色更像“幕后优化”，而不是对终端用户可见的能力标签**。¹¹

推理加速。相比 2025 旧材料，这一块需要显著提级到“和量化同等重要”。Apple 的 2025 技术报告给了非常硬的工程信号：它通过 **KV Cache Sharing** 把模型分为两个 block，让第二块共享第一块生成的 KV cache，从

而减少 37.5% KV cache 内存，并让 prefill 绕过第二块计算，把 TTFT 再降约 37.5%；同时 Apple 还提供可选 draft model 的端侧 speculative decoding。Google LiteRT-LM 在 2026 年把 Multi-Token Prediction 做进生产栈，官方给出最高 2.2x speedup，并展示 Gemma 4 E2B 在 Android GPU backend 上 52 tok/s、在 iOS Metal 上 56 tok/s 的 decode 速度。Alibaba MNN 的 Android 文档进一步声称，在 Qwen-7B 上其 CPU prefill 相比 llama.cpp 提高 8.6x，decode 提高 2.3x。这些迹象表明：端侧推理已经从“能跑起来”进入“毫秒级首 token、持续 decode、跨 backend pipeline 的全链路优化”阶段。 12

研究路线方面，Speculative Decoding、Medusa、EAGLE、Lookahead 仍是热点；而真正落在产品里的关键词则变成了 MTP、draft model、prefill bypass、session management、backend-specific kernels、缓存复用。也因此，旧材料只强调“端侧解码加速”已经不够，2026 年更准确的表述应是：prefill/decode 拆分优化、TTFT 优化、context reuse、KV 管理和 speculative family 已成为端侧体验差异化核心。 13

模型架构创新。Mamba/SSM、RWKV、Hybrid Transformer-SSM 在 2026 年继续被看好，原因是它们天然有望降低长上下文成本并改善内存/吞吐曲线。Jamba 用 Transformer + Mamba + MoE 的混合结构，Samba 用 Mamba + Sliding Window Attention，RWKV 则继续推进到 reasoning 版本的 RWKV-7 “Goose”。但必须实话实说：截至 2026 年上半年，公开可确认的主流手机 OEM 系统级基础模型，仍然以 Transformer 家族及其高效变体为主，SSM-first 在量产手机里的可见度并不高。因此这类架构在 2026 年更像“中长期潜力位”，特别适合长上下文、持续会话、低内存 edge 设备，而不是已经成为手机系统大一统架构。 14

长上下文、个性化、隐私。这一块在 2026 年已经从附加项升级为核心卖点。Gemma 3 提供 128K context，Phi-4-mini / Phi-4-multimodal 也是 128K，Apple 在 continued pretraining 中强化了 long-context understanding。个性化层面，Apple 官方已把 adapter training / rank-32 LoRA 做成开发者工具链；MediaTek 更直接把 on-device LoRA training 写进 Dimensity 9400 页面；这说明“设备上个性化适配”已不再只是论文题，而开始进入芯片厂商的公开能力宣传。隐私层面，Apple PCC 仍是行业最完整的“端上优先 + 私有云延展”方案，而 2026 年 Apple 又进一步把 PCC 扩展到 Google Cloud 上的 NVIDIA GPU 系统，同时宣称保留 Apple 同级别的隐私与安全保障；Meta/WhatsApp 也推出了 Private Processing，用 TEE 式安全云来承接 AI 功能。这意味着 2026 年“端云协同”已不再只是算力补充，而是带有隐私分级、可信执行环境、可验证透明性的体系设计。 15

端侧 Agent、GUI Agent、自动操作。旧材料只提“端侧大模型应用落地”，到 2026 年必须明确写成 Agent 化。Apple 的 Foundation Models framework 已经公开支持 tool calling；Gemma 3 支持 function calling 和 structured output；Samsung 在 Galaxy S25 上使用的是 multimodal AI agents；HONOR 把 YOYO Agent / UI Agent 直接推到产品叙事中心，并在 MWC 2025 展示基于屏幕理解和 GUI 操作的 agent；vivo 的 BlueOS 把 Agent framework 写进 OS 基础能力并在 2025 开发者大会披露开放 20+ 系统能力。研究侧，AutoDroid、PhoneGPT 综述、MagicGUI 等表明，手机自动化 agent 正从“可演示”走向“有数据集、有训练、有 benchmark 的独立赛道”。因此，2026 年端侧 AI 的关键差异项，已经不是“会不会聊天”，而是是否能理解屏幕、调用系统能力、完成跨 app 流程、在本地保留用户偏好上下文。 16

端侧专用芯片与 NPU。这已经从“支持 AI”变成“以 NPU 规格定义产品分层”。手机侧，Qualcomm Snapdragon 8 Elite 官方宣称其 Hexagon NPU 提供 45% AI 性能提升、45% performance-per-watt 提升；三星 Galaxy S25 全系采用 Snapdragon 8 Elite for Galaxy 并将其作为 on-device AI 核心卖点。MediaTek Dimensity 9400 公布 50 tok/s 多模态 LLM 性能、平均功耗较 9300 下降 35%、Stable Diffusion 提升 2x，并支持端侧 LoRA training。Apple M4 的 Neural Engine 达到 38 TOPS；Google Tensor G5 则被官方定义为首个运行 newest Gemini Nano 的芯片。PC 侧，Copilot+ PC 以 40+ TOPS NPU 为起点；Intel Core Ultra 200V NPU 最高 48 TOPS；AMD Ryzen AI 300 / PRO 300 达到 50-55 TOPS；Qualcomm Snapdragon X Elite 为 45 TOPS，X2 Elite 已到 80 TOPS。一句话总结：2026 年“能跑端侧大模型”已经不是高端芯片的附属能力，而是 SoC 代际定义的一部分。 17

端云协同、运行时与 benchmark。运行时层已经出现明确分野：Apple 有 Foundation Models + Core ML / MLX；Google 有 AICore、ML Kit GenAI API、LiteRT / LiteRT-LM；PyTorch 生态把 ExecuTorch 并入 PyTorch

Core; Qualcomm 有 AI Hub、QAI RT、ONNX Runtime Plugin EP; MediaTek 有 NeuroPilot 并与 LiteRT 打通 NPU; ONNX Runtime 继续做跨平台; llama.cpp/GGUF 仍是本地生态事实标准; MNN 和 ncnn 在中国/移动端维度非常强。Benchmark 层仍然分裂: MLPerf Inference / Tiny / Client 在标准化上最重要, 但对手机 LLM 的**真实用户体验 (TTFT、持续 tok/s、能耗、发热、后台稳态表现)** 仍缺一套行业统一、公开、可复现的“手机端大模型 benchmark”。从竞争情报角度, 这意味着未来真正重要的不只是 benchmark 分数, 而是**厂商是否能在自家芯片+系统+runtime+API+应用之间形成闭环。** ¹⁸

标杆厂商

下面给出一个更偏“端侧竞争情报”的横向表。为了保证表格可读, 我把最关键的公开信息压缩到“战略 / 端侧模型与技术 / 产品与 2025H2–2026 动态 / 护城河与短板”四列。

厂商	端侧 AI 战略定位	端侧模型、关键技术与公开产品	护城河与短板
Apple	系统级 “Apple Intelligence + PCC” 双层架构, 端上优先, 复杂任务私有云补位。WWDC 2025 推出 Foundation Models framework, WWDC 2026 推出 next-gen Siri AI。	公开技术报告确认 约 3B on-device model ; 支持图像理解、tool calling、LoRA adapter、optional draft model speculative decoding; 压到 2 bits-per-weight , KV cache 8bit ; 开发者可直接调用同一 on-device model, 且官方强调离线、免费本地推理; PCC 2026 扩展到 Google Cloud / NVIDIA GPU, 同时延续 Apple 隐私模型。 ¹⁹	护城河最深在 芯片、系统、runtime、API、隐私架构一体化 ; 短板是模型开放度较低、三方生态目前仍偏 Apple 平台内。
Google	Android 系统服务化路线: Gemini Nano + AICore + ML Kit GenAI API + LiteRT-LM , 同时用 Gemma 开源家族做生态外溢。	AICore 作为 Android 系统能力运行 Gemini Nano; 2025 推出 ML Kit Prompt API Alpha, 2026 进一步补充 Prompt API 等能力并预览 Nano 4 ; Gemma 3/3n/4 覆盖 1B 到 27B、E2B/E4B、音频/图像/视频输入; Tensor G5 成为 newest Gemini Nano 首发芯片; TalkBack 借 Gemini Nano 在离线/弱网下提供图像描述。 ²⁰	护城河在 Android 平台控制权、Gemini/Gemma 双生态、Google 服务上下文 ; 短板是 OEM 生态多样化, 体验一致性不如 Apple。
Samsung	“Galaxy AI” 从 feature bundle 走向 true AI companion / agentic AI phone 。	S25 被官方定义为引入 multimodal AI agents 的 AI companion; Live Translate 等功能长期押注 on-device; Gauss2 为多模态家族, 含 Compact / Balanced / Supreme; 2026 CES 继续强化 trust / privacy / AI living。 ²¹	护城河在 全球高端机出货、与 Qualcomm/Google 双合作、翻译与系统功能整合 ; 短板是底层模型与开发者 API 透明度不如 Apple / Google。

厂商	端侧 AI 战略定位	端侧模型、关键技术与公开产品	护城河与短板
Huawei	以 HarmonyOS + 小艺 + 盘古 为核心的自有 OS/生态路线。	HDC 2025 启动 HarmonyOS 6 Developer Beta，公开口径强调“无处不在的 AI 体验”；官方称 HarmonyOS 5 终端已超 40 款，30k+ 鸿蒙应用和元服务在加速，70+ 系统级创新体验；Pangu 5.0 继续强调多模态、多尺寸、强推理。 ²²	护城河在 中国本土 OS 与终端闭环、自主供应链与生态控制力 ；短板是公开技术细节（参数量、量化 bit、端侧 runtime 性能）透明度有限。
vivo	明确把 BlueOS / BlueLM / Agent framework 作为通向 AGI 时代的 OS 基础设施。	BlueOS 官方写明“系统架构深度融合蓝心大模型，Agent 框架具备跨场景感知、自主决策能力”；2025 vivo 开发者大会披露端侧大模型升级、开放 20+ 系统能力、支持跨端共享与复杂场景全流程执行；学术侧 vivo AI Lab 也是 PhoneGPT / 手机 GUI Agent 综述的重要作者来源。 ²³	护城河在 端侧 Agent、OS 级能力开放、对中国安卓生态理解深 ；短板是全球开发者心智与国际 API 影响力弱于 Google / Apple。
Xiaomi	把 HyperOS / HyperAI / 超级小爱 / AIOS 打成系统级一体化入口。	官方全球页面显示 Xiaomi HyperAI 内嵌 Google 深度定制 AI assistant，并用小米自有文本/语音/图像多模态处理增强生产力；2025 合作伙伴大会议程直接出现“超级小爱系统级体验”“小米端侧大模型”“与开发者共建新一代 AIOS”；HyperOS 3 页面披露“超级小爱深度研究、圈屏”等功能。 ²⁴	护城河在 人车家生态、多设备协同、对中国消费级场景的快速产品化 ；短板是核心基础模型与 runtime 的长期独占性仍较弱。
HONOR	把 AI Device Ecosystem Company 作为公司转型目标，重点压 YOYO Agent / UI Agent / MagicOS 。	MWC 2025 发布 HONOR ALPHA PLAN；Magic8 官方强调 next-generation YOYO Agent intelligence；MagicOS 10 官方页面持续强化 AI Screen Suggestions / agentic assistant；Wired 对其 UI Agent 报道指出，HONOR 展示了基于屏幕理解完成预订等任务的手机 GUI Agent。 ²⁵	护城河在 Agent 叙事、UI 自动化、与 Qualcomm/Google 合作 ；短板是全球市场规模与生态影响力仍有限。
OPPO	持续推进 AndesGPT / AI Phone 路线，但面向全球开发者与技术细节的公开披露相对碎片化。	可确认的公开动作包括 2025 AI Phone Reno14 系列与 OPPO AI 2025 发布会；但在“端侧模型参数量、量化 bit、端侧 Agent runtime”等维度，官方公开度明显低于苹果、Google、vivo、荣耀。 ²⁶	护城河在 硬件设计、全球渠道、AI 功能集成 ；短板是公开技术路线透明度和开发者平台声量不足。

厂商	端侧 AI 战略定位	端侧模型、关键技术与公开产品	护城河与短板
Lenovo / Motorola	走 Hybrid AI / 跨设备 ambient intelligence 路线。	Motorola 官方持续宣传 moto ai；CES 2026 Lenovo / Motorola 推出 Qira 作为跨 PC、平板、手机的 personal ambient intelligence；Lenovo 还在桌面端推出 AI Fusion Solution，支持本地 post-training fine-tuning 到 70B。 ²⁷	护城河在 PC+手机联动、企业场景、AI PC 结合；短板是单手机品牌端侧模型影响力不如头部手机厂。

再看芯片、模型与 AI PC 阵营，2026 年对端侧 AI 的影响更直接，因为它决定终端厂是否能把“模型能力”真正转成“系统级速度、续航与 API 能力”。 ²⁸

类别	代表玩家	2025H2–2026 关键信息	对端侧 AI 的意义
移动芯片	Qualcomm	Snapdragon 8 Elite 把 Hexagon NPU 提升 45% AI 性能 / 45% perf-per-watt ；AI Hub 可把 PyTorch / ONNX 模型转到 LiteRT、ONNX Runtime、QAI RT，并可在 50+ 设备 上实测；2026 又推出 ONNX Runtime Plugin EP。 ²⁹	护城河在 Android 高端机覆盖率和工具链完整度。
移动芯片	MediaTek	Dimensity 9400 给出 50 tok/s、35% lower power、2x Stable Diffusion、on-device LoRA training ；NeuroPilot 强调 CPU/GPU/NPU 异构协同；LiteRT 的 MediaTek NPU 支持已向所有开发者开放。 ³⁰	护城河在高能效与面向中国安卓阵营的大规模出货。
Apple Silicon	Apple	M4 Neural Engine 38 TOPS ；MLX / MLX-LM / Foundation Models toolkit 构成 Apple silicon 本地训练与推理生态。 ³¹	护城河在统一内存与 Apple 全栈优化。
Google 自研芯片	Tensor	Tensor G5 被官方定义为 newest Gemini Nano 首发芯片。 ³²	重点不在绝对 TOPS，而在 Pixel 首发 AI 体验与 Android 系统化分发。
AI PC	Microsoft / Intel / AMD / Qualcomm	Copilot+ PC 以 40+ TOPS 为门槛；Intel Core Ultra 200V 48 TOPS NPU ；AMD Ryzen AI 50–55 TOPS ；Snapdragon X Elite 45 TOPS 、X2 Elite 80 TOPS ；Windows Search / Recall 等功能可本地、离线运行；2026 Build 推进 Foundry Local。 ³³	AI PC 已经成为“8B+、长上下文、多工具编排”的重要承接平台。

类别	代表玩家	2025H2–2026 关键信息	对端侧 AI 的意义
模型厂 商 / 开源 小模型	Qwen /	Qwen3 把 hybrid thinking 变成产品特性，并继续推 edge-to-cloud 的 dense / MoE；Qwen3-Omni	2026 端侧模型竞赛已经进入“谁能用更少 active footprint 做出更强 agentic + multimodal 体验”。
	DeepSeek /	进入音频/视频/文本全模态；DeepSeek-R1 用开放蒸馏把 reasoning 下沉到 1.5B–70B；Gemma 3n /	
	Google /	4 E2B/E4B 强化移动端；Phi-4 mini 与	
	Microsoft /	multimodal 主打 128K；Minstral 3 直接给出 3B/	
	Mistral /	8B/14B 的 edge family；MiniCPM-V 4.5 在 iPad	
	OpenBMB / HF	M4 有公开 demo；SmolLM3-3B 主打	
	/ Meta	multilingual、long-context、dual-mode reasoning；Meta 的 MobileLLM / MobileLLM-Pro	
		则继续卡位 sub-1B on-device。 ³⁴	

从实际可用性出发，当前最值得关注的端侧小模型清单可以概括为：Apple on-device AFM（约 3B，系统级封闭但体验与隐私强）、Gemma 4 E2B/E4B（移动边缘优化，LiteRT/AICore 生态最完整）、Gemma 3n（低 RAM 多模态）、Qwen3 4B / Qwen3-VL edge variants（中文强、thinking/non-thinking 清晰）、DeepSeek-R1-Distill-Qwen-1.5B / 7B / 8B（reasoning 性价比极高）、Phi-4-mini-instruct / multimodal（长上下文与桌面友好）、SmolLM3-3B（开源与多语种友好）、Minstral 3 3B/8B（企业端边缘部署友好）、MiniCPM-V 4.5（移动多模态强），以及 Meta 的 MobileLLM-Pro（更偏研究和未来移动产品储备）。 ³⁵

用户需求与杀手场景

旧材料中的“三大需求”——高隐私、高速度、弱网/无网可用——到 2026 年不仅仍然成立，而且被验证为端侧 AI 最稳定的价值锚。Google 的开发者文档明确把 Gemini Nano 定义为运行在 AICore 中、可依赖设备硬件实现 **low inference latency** 的 on-device foundation model；Android 官方还展示 Gemini Nano 多模态在 **离线或网络不稳定** 情况下为 TalkBack 提供图像辅助；Apple Developer 则直接把 Foundation Models framework 的价值写成 **offline、privacy-protecting、AI inference free of cost**。这说明端侧 AI 的需求本质没有改变：用户并不关心“端侧”这个词本身，用户关心的是快、稳、私密、不断网时也能用。 ³⁶

但与 2025 不同的是，2026 年新增三个更强烈的需求层：**零云端成本、个性化、Agent 化代办**。“零云端成本”既是用户的隐性需求，也是厂商和开发者的显性需求：Apple 已把 on-device model 的开发者调用定义成 **free of cost**，并且对小开发者开放了无云 API 成本的 PCC 使用门槛；这意味着很多轻量生成、摘要、结构化提取和本地问答场景，不再需要每次付云推理费用。个性化方面，Apple 的 adapter training 与 MediaTek 的 on-device LoRA training 显示，“让设备学习用户，而不是把用户数据都送上云”已开始从理念进入工具链。Agent 化方面，Google、HONOR、vivo、Samsung、Lenovo/Motorola 都在把 AI 从“回答问题”转成“替你处理任务、预判下一步、跨 app/跨设备协作”。 ³⁷

市场与调研数据也印证了需求在加速成形。We Are Social 转引 GWI 的 2025Q4 研究显示，**81.2% 的全球在线成年人在过去一个月内使用过至少一种 AI**；Deloitte 2025 Connected Consumer 调研则显示，gen AI 用户最常通过 **手机上的独立 AI app（65%）** 和内嵌于熟悉软件中的 AI（69%）来使用 AI，同时 **24% 的用户报告经历过数据隐私问题**。手机仍是 AI 最自然、最高频的入口，但也是隐私敏感度最高的入口。与此同时，Canalys/Omdia 预测 **AI-capable smartphones 到 2028 年将占全球出货的 54%**，Counterpoint 早在 2024 年就预测 2027 年 GenAI 手机占比将达 **43%**；Reuters 报道中 Counterpoint 也认为 2025 年 GenAI 手机出货将超过 **4 亿台**。这些数字虽然带有研究机构模型假设，但足以说明：**端侧 AI 已不是一线旗舰的噱头，而是在向中高端智能手机与 AI PC 的基础能力演进。** ³⁸

从需求拆解看，2026 年最值得写进材料的用户价值主张至少包括以下几项。第一是**强隐私与数据本地化**：随着 AI 滥用和数据泄露担忧上升，AI 用户对“数据会不会被上传、会不会被训练、会不会泄漏”越来越敏感，Deloitte 官方调研已经出现用户遭遇隐私问题的数据，WhatsApp Private Processing 与 Apple PCC 的出现也

说明行业主流正在向“可信端云”靠近。第二是**低延迟实时性**：实时翻译、辅助视觉描述、通话助理、屏幕理解、语音到操作链路，都只有在本地几十到几百毫秒级响应时才成立。第三是**续航 / 功耗**：MediaTek 把 35% 降功耗直接写进 9400 页面，Qualcomm 把 perf-per-watt 提升写成旗舰卖点，这说明功耗已经成为端侧 AI 体验能否长期打开的硬约束。³⁹

第四是**主动式 / 预测式 AI**。Google 在 Pixel 10 上用 Tensor G5 + Gemini Nano 推了 Magic Cue、Voice Translate、Gemini Live 等能力；Samsung 用“AI companion”“Now Brief”等产品化叙事说明手机 AI 正从“等你发问”转向“根据上下文提前呈现信息与行动建议”；Lenovo / Motorola Qira 则把这种上下文能力扩展到跨手机、平板、PC 的场景。旧材料里的“高速度”在 2026 年必须更新成更精确的需求表述：**用户想要的不是更快的聊天，而是更快地完成上下文感知、任务编排和实际动作执行。**⁴⁰

第五是**无障碍与适老化**。这是 2026 年端侧 AI 非常容易被低估，但商业和社会价值都很大的方向。Google 已经把 Gemini Nano 多模态用在 TalkBack 上，支持在离线/弱网下做更详细的图像描述；这类能力天然适合做老年人、低视力、认知负担较高场景的辅助入口。相比云端方案，端侧版在隐私与响应上都更容易获得信任。第六是**多模态自然交互**，即用户不再满足于“打字问一句”，而是希望“说一句、拍一下、圈一下、把当前屏幕丢给 AI，它就知道我要什么”。Gemma 3n、Gemma 4、Phi-4-multimodal、Qwen3-Omni、Apple AFM、Galaxy AI、HyperAI 都在往这个方向推进。⁴¹

如果要提炼**杀手级端侧应用场景**，2026 年最有确定性的仍然是六类。其一是**实时翻译 / 同传 / 通话翻译**：Samsung 的 Live Translate 已长期强调 on-device；Pixel 10 官方也把 Voice Translate 作为 Gemini Nano 能力之一。其二是**通话与会议助理**：摘要、转录、提醒、行动项提取，在弱网与隐私敏感场景下极适合本地推理。其三是**相册 / 影像本地编辑和检索**：生成式编辑、图像增强、视频裁剪、语义检索，已经成为几乎所有高端 AI 手机的共识功能。其四是**本地语音助手与屏幕理解**：YOYO Agent、Super XiaoAI、Gemini on Pixel、Siri AI 都在向这一方向收敛。其五是**GUI Agent / 自动操作**：自动预约、打开 app、跨 app 搬运信息、执行设置操作。其六是**本地知识问答与敏感数据处理**：包括工作文档、聊天记录、健康数据、家庭隐私内容。特别是在法规趋严、企业 BYOD 加速的背景下，“**不出设备的企业 / 个人知识助理**”会越来越有吸引力。⁴²

相比 2025 旧材料的关键变化

与 2025 年那页旧材料相比，以下判断建议明确更新，甚至部分推翻：

- “**端侧模型能力和规模**”需要改写。不应再用“3B/7B 持续变强”概括，而应改成“**1B 以下—4B 左右成为手机/可穿戴/低功耗设备主甜点区间，8B 左右高效多模态模型转向平板/AI PC/高端端侧，云端负责更复杂 agentic reasoning**”。Apple 的约 3B、Gemma 4 E2B/E4B、Gemma 3n、Phi-4-mini、SmolLM3、Minstral 3 等都支持这一点。⁴³
- “**量化重要**”远远不够，应该升级为“**量化 + KV Cache + TTFT 是端侧第一性工程问题**”。2026 年更强的事实是：Apple 已公开量产级 **2bpw + 8bit KV cache**；Gemma 4 已提供官方 QAT；LiteRT-LM、MNN、llama.cpp 都把底层推理优化做成核心产品能力。⁴⁴
- “**端侧多模态**”从探索变成了主流。旧材料虽然提到多模态趋势，但 2026 年应明确写为：**图像、音频、视频、屏幕内容理解已成为端侧模型的标准期望，而不是加分项**。Gemma 3n/4、Phi-4-multimodal、Qwen3-Omni、Apple AFM、Galaxy AI 都已在公开资料中走到这一阶段。⁴⁵
- “**端侧 reasoning**”必须新增，且要高权重。DeepSeek-R1 蒸馏、Qwen3 hybrid thinking、SmolLM3 dual mode reasoning 都说明“推理模型下沉到小模型和端侧”已经是现实路线。⁴⁶
- “**生态共建**”已经从原则变成了具体 **API / runtime / NPU 之争**。2025 的表述偏正确但过于泛化；2026 要写清楚是 Apple Foundation Models、Android AICore + ML Kit、LiteRT-LM、Qualcomm AI Hub / QAIRT、NeuroPilot、ExecuTorch、MNN、ncnn、Foundry Local 这类**具体平台竞争**。⁴⁷
- “**用户需求**”要从**隐私/速度/弱网**，扩展到“**零云成本、个性化、主动式 Agent、无障碍**”。这不是概念补充，而是产品和商业模式都在往这个方向走：Apple 直接把本地推理写成 free-of-cost；TalkBack 证明多模态端侧 AI 也能成为 accessibility 基础设施；HONOR / vivo / Google / Lenovo 则把 Agent 化和上下文主动性前置。⁴⁸

- “标杆厂商”名单也要更新。2025 看苹果、vivo、小米、阿里 Qwen-Omni 还算够用；到 2026 必须把 **Google、Samsung、Apple、HONOR、vivo、Xiaomi、Huawei、Qualcomm、MediaTek、Microsoft AI PC、Gemma / Phi / DeepSeek / MiniCPM / Ministral / SmolLM** 都纳入长期跟踪池。

49

综合来看，2025 旧材料的方向没有错，但对 2026 来说已经明显“颗粒度不够”。更准确的更新版主张应该是：端侧大模型不再是单点 AI 功能，而是设备 OS、NPU、runtime、系统 API、隐私架构、跨端上下文和 agentic execution 的综合竞争。谁能把“本地小模型 + 私密云补位 + 工具调用 + 系统动作执行 + 低功耗稳态”做成平台能力，谁就更接近 2026 之后真正的 AI 终端操作系统。

50

🌐navlist🌐近期端侧AI与AI终端相关新闻

🌐turn31news20,turn32news36,turn32news37,turn4news36,turn37news28,turn37news29🌐

1 2 7 9 12 19 35 43 44 Apple Intelligence Foundation Language Models: Tech Report 2025
https://machinelearning.apple.com/papers/apple_intelligence_foundation_language_models_tech_report_2025.pdf

3 34 Qwen3: Think Deeper, Act Faster
https://qwenlm.github.io/blog/qwen3/?utm_source=chatgpt.com

4 LiteRT-LM Overview | Google AI Edge
https://ai.google.dev/edge/litert-lm/overview?utm_source=chatgpt.com

5 Qwen3-VL is the multimodal large language model ...
https://github.com/qwenlm/qwen3-vl?utm_source=chatgpt.com

6 8 46 DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning
https://arxiv.org/abs/2501.12948?utm_source=chatgpt.com

10 KIVI: A Tuning-Free Asymmetric 2bit Quantization for KV Cache
https://arxiv.org/abs/2402.02750?utm_source=chatgpt.com

11 SparseGPT: Massive Language Models Can Be Accurately ...
https://arxiv.org/abs/2301.00774?utm_source=chatgpt.com

13 Medusa: Simple LLM Inference Acceleration Framework with Multiple Decoding Heads
https://arxiv.org/abs/2401.10774?utm_source=chatgpt.com

14 Jamba: A Hybrid Transformer-Mamba Language Model
https://arxiv.org/abs/2403.19887?utm_source=chatgpt.com

15 Gemma 3: Google’s new open model based on Gemini 2.0
<https://blog.google/innovation-and-ai/technology/developers-tools/gemma-3/>

16 Deep dive into the Foundation Models framework - WWDC25 ...
https://developer.apple.com/videos/play/wwdc2025/301/?utm_source=chatgpt.com

17 29 Snapdragon 8 Elite Mobile Platform
https://www.qualcomm.com/smartphones/products/8-series/snapdragon-8-elite-mobile-platform?utm_source=chatgpt.com

18 47 Apple Intelligence - Apple Developer
https://developer.apple.com/apple-intelligence/?utm_source=chatgpt.com

20 36 Gemini Nano | AI
https://developer.android.com/ai/gemini-nano?utm_source=chatgpt.com

- 21 **Galaxy S25 Series**
https://news.samsung.com/global/galaxy-s25?utm_source=chatgpt.com
- 22 **HarmonyOS 6 开发者Beta正式启动：打造无处不在的AI体验**
https://www.huawei.com/cn/news/2025/6/harmonyos6-hms-hdc?utm_source=chatgpt.com
- 23 **BlueOS-蓝河操作系统**
https://blueos.vivo.com/?utm_source=chatgpt.com
- 24 **Xiaomi HyperAI | Xiaomi® Global**
https://www.mi.com/global/brand/ai/xiaomi-hyperai?utm_source=chatgpt.com
- 25 **HONOR Unveils New Corporate Strategy to Transition ...**
https://www.honor.com/global/news/honor-alpha-mwc-2025/?utm_source=chatgpt.com
- 26 **OPPO Launches AI Phone Reno14 Series and Upgraded ...**
https://hr.asia/media-outreach/oppo-launches-ai-phone-reno14-series-and-upgraded-ai-powered-intelligent-after-sales-service-system/?utm_source=chatgpt.com
- 27 **Moto AI Smart Services and Solutions for Smarter Business**
https://www.motorola.com/us/en/moto-ai?srsltid=AfmBOoqYsjcixm5CLADPbZrKPwBOJwwAzJNV5qmG7JxHNld4qEPZ0lWR&utm_source=chatgpt.com
- 28 **Qualcomm AI Hub**
https://aihub.qualcomm.com/?utm_source=chatgpt.com
- 30 **MediaTek Dimensity 9400 – Flagship 5G Agentic AI Platform**
https://www.mediatek.com/dimensity-9400?utm_source=chatgpt.com
- 31 **Apple introduces M4 chip**
https://www.apple.com/newsroom/2024/05/apple-introduces-m4-chip/?utm_source=chatgpt.com
- 32 **Pixel 10 introduces new chip, Tensor G5**
https://blog.google/products-and-platforms/devices/pixel/tensor-g5-pixel-10/?utm_source=chatgpt.com
- 33 **Copilot+ PCs are the most performant Windows PCs ever built ...**
https://blogs.windows.com/windowsexperience/2025/04/25/copilot-pcs-are-the-most-performant-windows-pcs-ever-built-now-with-more-ai-features-that-empower-you-every-day/?utm_source=chatgpt.com
- 37 **Accessing Private Cloud Compute**
https://developer.apple.com/private-cloud-compute/?utm_source=chatgpt.com
- 38 **Digital 2026 Mid-Year Global Update Report - We Are Social**
https://wearesocial.com/th/blog/2026/04/digital-2026-mid-year-global-update-report/?utm_source=chatgpt.com
- 39 **2025 Connected Consumer: Innovation with trust**
https://www.deloitte.com/us/en/insights/industry/telecommunications/connectivity-mobile-trends-survey.html?utm_source=chatgpt.com
- 40 **9 ways AI makes Pixel 10 our most helpful phone yet**
https://blog.google/products-and-platforms/devices/pixel/google-pixel-10-ai-features-updates/?utm_source=chatgpt.com
- 41 **AI on Android | Android Developers**
https://developer.android.com/ai?utm_source=chatgpt.com
- 42 **Use Live Translate on Galaxy phones and tablets**
https://www.samsung.com/us/support/answer/ANS10000935/?utm_source=chatgpt.com

45 **google/gemma-3n-E4B-it**

https://huggingface.co/google/gemma-3n-E4B-it?utm_source=chatgpt.com

48 **Apple's Foundation Models framework unlocks new ...**

https://www.apple.com/newsroom/2025/09/apples-foundation-models-framework-unlocks-new-intelligent-app-experiences/?utm_source=chatgpt.com

49 50 **Apple Intelligence brings powerful AI capabilities into ...**

https://www.apple.com/newsroom/2026/06/apple-intelligence-brings-powerful-ai-capabilities-into-everyday-experiences/?utm_source=chatgpt.com