

2026 年端侧 AI / 终端侧大模型整合报告

面向 OPPO 端侧化小组的三源材料合并版

0. 一页速览 (TL;DR)

1. **端侧 AI 从“模型压缩 + 离线隐私”升级为系统工程**：2026 年竞争焦点变为“端侧模型家族 + NPU/runtime + 系统 API + 端云隐私路由 + Agent 化执行”。单纯讨论“手机能不能跑 7B”已不够。[3/3]
 2. **模型规模锚点下移并分层**：手机主甜点区间更偏 **sub-1B 到 4B**；8B 以上更多面向高端手机、平板、AI PC 或 aggressive quantization；MoE/有效激活参数成为提升上限的新路径。[3/3]
 3. **量化进入硬工程阶段**：4-bit 是通用工程基线；Apple 约 3B 端侧模型的 **2-bit QAT + 8-bit/KV cache 或 KV cache sharing** 是可确认的量产级标杆；1-bit/1.58-bit 仍是高潜力但需核验的前沿方向。[3/3，1.58-bit 存冲突]
 4. **KV Cache、TTFT、prefill/decode 拆分成为第一性问题**：端侧生成的瓶颈不只是算力，而是内存带宽、KV cache、首 token 延迟、持续 decode、功耗和发热。[3/3]
 5. **推理模型下沉到小模型**：DeepSeek-R1 蒸馏、Qwen3 hybrid thinking、SmolLM3 dual-mode reasoning、Phi/Gemma/MiniCPM 小模型后训练，都说明“端侧 reasoning”应作为 2026 新增技术方向。[3/3]
 6. **GUI Agent / Phone Agent 成为手机厂商新主战场**：荣耀 YOYO/MagicGUI、vivo PhoneGPT/蓝心小 V、华为 HMAF、小米超级小爱、Apple/Google/Samsung 的 tool/function calling 与屏幕理解路线，都在把 AI 从“回答问题”推向“替用户完成任务”。[3/3]
 7. **NPU 与 runtime 正在决定真实体验**：Qualcomm AI Hub/QNN、MediaTek NeuroPilot/LiteRT、Apple Foundation Models/Core ML/MLX、Google AICore/LiteRT、ExecuTorch、llama.cpp/GGUF、ONNX Runtime、MNN/ncnn 等成为端侧生态核心。[3/3]
 8. **用户需求从“隐私、速度、弱网”扩展到“零云成本、个性化、主动式 Agent、无障碍、自然多模态交互”**。[3/3]
 9. **OPPO 的机会点不是单个大模型参数，而是 OEM 护城河**：系统级 I/O、权限、传感器、影像链路、端侧记忆、A2A/GUI 兜底、与 MediaTek/Qualcomm 的深度联合优化。[Claude+Gemini，ChatGPT 对 OPPO 更保守]
 10. **Gemini 材料中若干“未来事实”应单列核验**：如 DeepSeek V4-Flash、iPhone 17 Pro 跑 400B Flash-MoE、iOS 27/WWDC26 Siri、OPPO Find X9 端侧 Omni、Android 17/Gemma 3 常驻 API 等，不宜直接进入正式材料。[仅Gemini/冲突]
-

1. 技术趋势

1.1 端侧模型规模与架构：从“7B 为底”到“1B–4B 甜点区间 + MoE 抬上限”

- 端侧模型规模不再线性抬升，而是分层：
 - sub-1B: SmolLM2 135M–1.7B、Gemma 3 270M、Qwen2.5 0.5B/1.5B；
 - 1–4B: Llama 3.2 1B/3B、Phi-4-mini 3.8B、Gemma 3n E2B、Apple 约 3B on-device foundation model；
 - 8B+: 更偏高端手机/平板/AI PC/离线工作站，或依赖 4-bit/2-bit/MoE/流式加载。[Claude+ChatGPT]
- ChatGPT 版给出的保守判断最适合作为主口径：2026 量产端侧甜点区间更像 **1B–4B 高效率 dense/有效参数模型**，而不是 7B 单一路线；3B 仍是系统级基础模型合理中心点，但产品组合将转向“sub-1B 辅助模型 + 2B/4B 主模型 + 云端大模型/Agent 编排”。[ChatGPT]
- MoE/有效激活参数是端侧上限突破方向：
 - Qwen3-Omni-30B-A3B: 30B 总参数、3B 激活，全模态 Thinker-Talker 架构，Claude 版给出 234ms 理论首包、119 文本语言/19 语音输入/10 语音输出等细节；
 - Gemma 4 26B-A4B: Claude 版称激活 4B、消费级硬件 85 tok/s；
 - MobileMoE: Gemini 版称 0.3B–0.9B 活跃参数、1.3B–5.3B 总参数，MobileMoE-S 在 INT4 下 prefill 提升 1.8–3.8×、decode 提升 2.2–3.4×。[3/3, MobileMoE 仅Gemini]
- 端侧 MoE 的正式量产程度仍需谨慎表述：ChatGPT 版提醒，公开量产手机中的“显式端侧 MoE”案例仍有限，更多表现为低 RAM footprint 的边端规格、MoE 训练策略、总量大/激活小的模型族，而非每家 OEM 都已大规模量产端侧 MoE。[ChatGPT]
- 超大 MoE 流式加载应放入前沿/存疑：Gemini 版称 Flash-MoE 可在 12GB 设备上运行 400B MoE、每 token 只调入约 2% 专家、iPhone 17 Pro 上 0.6 tok/s。该信息仅一份提到且来源像二级文章，建议标为“前沿探索/需核验”，不要作为既成量产事实。[仅Gemini/需核]

1.2 数据蒸馏与模型蒸馏：端侧 reasoning 的现实路径

- DeepSeek-R1 蒸馏路线是三份材料共同强调的关键范式：大模型生成高质量 CoT/推理轨迹，再蒸馏到 1.5B/7B/8B/14B/32B/70B dense students；Claude 版强调 80 万条推理样本仅 SFT、无 RL 阶段，并称 R1-Distill-Qwen-1.5B 在部分数学基准超过 GPT-4o/Claude-3.5-Sonnet。[3/3]
- 对手机厂商的意义：端侧小模型最现实的上线路径不是从零训练，而是“大 teacher 造数据 → 小模型蒸馏 → 设备/场景后训练 → NPU/runtime 专项优化”。[3/3]
- 蒸馏能力不只来自 logit：Gemini 版补充了 feature-level distillation、CoT 高信号轨迹过滤、AutoMixer、target-aware language modeling 等更细方向，但后两者仅一份提到，建议作为“可跟踪研究方向”。[仅Gemini]

1.3 预训练与后训练：SFT、DPO、RL、hybrid thinking、GUI RFT

- 小模型后训练四大支柱：SFT、DPO/preference optimization、纯 RL reasoning、hybrid thinking。[ChatGPT+Claude]

- **Qwen3 hybrid thinking/non-thinking 是 2026 端侧体验的重要范式：**复杂任务慢思考，简单任务 near-instant 快速回答；Claude 版称 Qwen3-4B 可媲美 Qwen2.5-72B-Instruct，Qwen3-30B-A3B 超越激活参数 10× 的 QwQ-32B。[3/3]
- **Apple 的系统级后训练工具链值得关注：**Apple 端侧约 3B 模型使用合成数据、授权语料、SFT/RL；Foundation Models 框架开放 LoRA adapter、guided generation、constrained tool calling。[Claude+ChatGPT]
- **GUI Agent 后训练出现专门范式：**荣耀 MagicGUI 采用 CPT 注入 GUI 知识，再用 RFT/空间增强复合奖励/DF-GRPO 强化屏幕感知和定位。[Claude]

1.4 量化：4-bit 工程基线，2-bit 进入标杆量产，1.58-bit 需核验

- **保守结论：**
 - 4-bit：开发者与开源生态最主流；
 - 2-bit：已有明确系统级量产标杆，尤其 Apple 约 3B on-device model 的 2-bit QAT；
 - 1-bit/1.58-bit：研究和实验很活跃，但是否“主流手机 OEM 大规模量产”三份材料存在冲突。[3/3]
- **Apple 量化细节最适合作为确定性案例：**约 3B 端侧模型使用 2-bit QAT；ChatGPT 版补充 embedding table 4-bit、KV cache 8-bit；Claude 版补充 KV-cache sharing，把模型分两块，Block1 含 62.5% transformer 层，Block2 含 37.5% 且去掉 K/V 投影，KV cache 内存和 TTFT 均约降 37.5%。[Claude+ChatGPT]
- **BitNet b1.58 信息需拆开写：**
 - Claude 版：BitNet b1.58 2B4T，三值权重 {-1,0,+1}、激活 8-bit、2B 参数/4T tokens、bitnet.cpp 能耗下降 55.4%–70%，但官方未建议直接商用；
 - Gemini 版：称 ENERZAI 等通过高通 Hexagon DSP 手写 1.58-bit 三值算子，已跨过商用门槛；
 - ChatGPT 版：更保守，认为 1-bit/1.58-bit 仍主要在研究/实验阶段，未见主流手机 OEM 官方大规模量产披露。
建议正式材料采用 ChatGPT 的保守口径：1.58-bit 是战略前沿，需核实芯片/SDK/量产状态。[3/3 冲突]
- **KV Cache 量化成为长上下文端侧部署核心：**Claude 版提 KIVI 2-bit KV cache（峰值内存降 2.6×、batch 可大 4×、吞吐量 2.35–3.47×），以及 KVtuner、MixKVQ、RotateKV、KVQuant；Gemini 版补充 TurboQuant、Kitty、“Don’t Waste Bits!”等，但这些需单独核验。[Claude+Gemini]
- **PC/AI PC 仍大量使用 INT8：**Copilot+ PC 的 40 TOPS 门槛通常按 INT8 计，Claude 版明确提 FP32→INT8 约 4× 提速、精度损失小。因此 Gemini 版“传统 8bit 已被主流厂商完全抛弃”表述过度，应删除或改为“手机端生成模型趋向 4-bit/2-bit，但 PC/NPU 生态仍大量以 INT8 标称和部署”。[Claude vs Gemini 冲突]

1.5 稀疏化、剪枝与激活稀疏

- **稀疏化在研究和幕后优化中重要，但在 OEM 发布会中不如量化/MoE 显眼。**[ChatGPT]
- **关键方法池：**SparseGPT、Wanda、结构化剪枝、非结构化剪枝、R-Sparse、CHESS、ReLU Strikes Back、PowerInfer、TEAL、ProSparse、Deja Vu。[Claude+Gemini]

- **工程判断**：非结构化稀疏需要稀疏矩阵支持；结构化剪枝（删 head/layer/channel）更容易在标准移动硬件上获得真实速度收益；激活稀疏有助于 decode 阶段降 FLOPs、降发热。[3/3]

1.6 推理加速：TTFT、prefill/decode、MTP、投机解码、Flash I/O

- **端侧推理**已从“能跑”进入“首 token、持续 decode、缓存复用、功耗稳态”阶段。[3/3]
- **投机解码主流路线**：Medusa（多解码头，2.2–3.6×）、EAGLE（hidden state 外推，EAGLE-3 融合多层语义）、Lookahead、draft model、MTP、cross-vocabulary speculative decoding。
[Claude+ChatGPT]
- **Apple 工程信号强**：KV cache sharing + prefill bypass 可降低 KV 内存/TTFT；端侧 optional draft model speculative decoding 是系统级路线的一部分。[Claude+ChatGPT]
- **Google/LiteRT-LM/MTP**：ChatGPT 版称 LiteRT-LM 将 Multi-Token Prediction 做进生产栈，最高 2.2× speedup；Gemma 4 E2B 在 Android GPU backend 52 tok/s、iOS Metal 56 tok/s。[ChatGPT]
- **FastVLM/Qualcomm 实测是强素材**：FastVLM-0.5B 在 Snapdragon 8 Elite Gen 5 / LiteRT QNN 上处理 1024×1024 图像，TTFT 0.12s、prefill >11,000 tok/s、decode >100 tok/s；Claude 和 Gemini 都提到该数字。[Claude+Gemini]
- **Gemini 的 Lever/PELM/SLED 可放前沿跟踪**：Lever 针对 Flash I/O，将草稿模型常驻 DRAM、大模型保留 Flash；Gemini 称 Llama-3.1-8B 直接从 Flash 读权重时 I/O 占整步 91.4%，PELM 最高 13.5× TTFT 加速、峰值能耗降 24×。这些仅 Gemini 提到，建议核验后再用于正式材料。[仅Gemini/需核]

1.7 模型架构创新：Transformer 仍主流，SSM/Mamba/RWKV 是中长期方向

- **ChatGPT 版保守判断适合作为主口径**：Mamba/SSM、RWKV、Hybrid Transformer-SSM 有潜力降低长上下文成本，但截至 2026H1，主流手机 OEM 系统级基础模型仍以 Transformer 及其高效变体为主。[ChatGPT]
- **可列技术池**：Mamba/SSM、RWKV、Jamba、Zamba、Samba、Qwen Gated Delta-Net、DeepSeek mHC、Apple PT-MoE、Qwen3-Omni Thinker-Talker MoE、Gemma 4 encoder-free multimodal。
[3/3]

1.8 长上下文、个性化、隐私

- **长上下文正在进入端侧叙事，但真实可用长度受 RAM/KV/热设计限制**：Claude 提 D9500 支持 128K、Qwen3.5 端侧 32K；ChatGPT 提 Gemma 3、Phi-4-mini/multimodal 128K；Gemini 提 DeepSeek V4-Flash 1M context，但该项需核。[3/3，1M 仅Gemini/需核]
- **端侧个性化从理念进入工具链**：Apple LoRA adapter、rank-32 adapter training；MediaTek Dimensity 9400 页面据 ChatGPT/Gemini 称支持 on-device LoRA training；OPPO 记忆引擎端侧化，小米超级小爱端侧加密记忆可清空。[3/3]
- **隐私架构成为端云协同基础**：Apple PCC、Google AI Core/Private Compute Core、华为 HPIC/星盾、Meta/WhatsApp Private Processing、TEE、联邦学习等构成“端侧优先 + 私密云补位”范式。[3/3]

1.9 端侧 Agent & GUI Agent

- **2026 年端侧 Agent 的竞争重点是屏幕理解、系统 API、跨 App 执行、权限安全、任务成功率，而非聊天能力。** [3/3]
- **荣耀是三份材料中最强共识案例之一：**YOYO Agent / MagicGUI / MagicOS，跨 App 执行，3000+ 场景、4000+ 生态智能体、L3 认证、MagicGUI 7B 开源等细节主要来自 Claude，ChatGPT/Gemini 也强调 HONOR 的 UI Agent 战略。 [3/3，数字需核]
- **vivo PhoneGPT / 蓝心小 V：**识屏、接管音频、自主对话完成订餐/订咖啡；2025 vivo 开发者大会称 3B 端侧 Agent 模型，开放 20+ 系统能力，建立本地知识图谱/共同记忆。 [Claude+ChatGPT+Gemini]
- **华为 HMAF / 小艺智能体开放平台：**操控、伴随、GUI 任务、任务协同，A2A+MCP，首批 80+ 智能体，天工计划 10 亿元；隐私侧主打 HPIC/星盾。 [Claude+Gemini]
- **字节/中兴豆包 AI 手机：**Claude 版称 2025-12 工程样机、3 万台秒罄、二手溢价 >3500 元，系统级 GUI Agent 越过应用沙盒直接读屏点屏。该信息仅一份提到，建议核验。 [仅Claude/需核]
- **OPPO 路线差异：**Claude 版指出 OPPO 倾向 A2A 接口而非纯 GUI 路线，视 GUI 为长尾兜底；这对内部战略有参考价值：OPPO 可把 A2A 做成稳定主路径，GUI Agent 做长尾补全。 [仅Claude]

1.10 专用芯片/NPU：SoC 代际定义的一部分

- **Qualcomm：**Snapdragon 8 Elite / 8 Elite Gen 5、Hexagon NPU、AI Hub、QNN/QAIRT、ONNX Runtime Plugin EP；材料中反复出现 +45% AI 性能、+45% perf-per-watt、FastVLM 0.12s TTFT、prefill >11k tok/s 等数字。 [3/3]
- **MediaTek：**三份材料存在代际混用：ChatGPT/Gemini 聚焦 Dimensity 9400/APU 890（50 tok/s、多模态、功耗 -35%、Stable Diffusion 2×、on-device LoRA training）；Claude 聚焦 D9500/NPU 990（100 TOPS、BitNet 1.58、compute-in-memory、UFS4.1 4 通道、大模型加载快 40%）。正式材料需核对 9400/9500/9500s 的发布时间、规格和商业命名。 [3/3 冲突]
- **Apple Silicon：**Apple A19/A19 Pro、M4 Neural Engine 38 TOPS、ANE + GPU Neural Accelerators、统一内存、Core ML/MLX/Foundation Models 是闭环优势。 [Claude+ChatGPT]
- **AI PC：**Copilot+ PC 以 NPU ≥ 40 TOPS 为门槛；Intel Core Ultra 200V 48 TOPS；AMD Ryzen AI 300/PRO 300 50-55 TOPS；Snapdragon X Elite 45 TOPS、X2 Elite 80 TOPS；Windows Recall、Live Captions、Cocreator、Click to Do、Phi Silica、Foundry Local/Windows ML 构成端侧 PC 生态。 [Claude+ChatGPT]

1.11 端云协同与运行时

- **端云协同范式：**端侧处理高频、敏感、低延迟任务；云端处理长上下文、复杂 reasoning、联网知识、跨服务任务；核心是按隐私等级、任务难度、网络状态、能耗预算动态路由。 [3/3]
- **主流运行时/框架清单：**
 - Apple：Foundation Models、Core ML、MLX/MLX-LM；
 - Google：AICore、ML Kit GenAI API、LiteRT/LiteRT-LM；
 - PyTorch/Meta：ExecuTorch；

- Qualcomm: AI Hub、QNN/QAIRT、Genie、ONNX Runtime Plugin EP;
- MediaTek: NeuroPilot、LiteRT NPU delegate;
- 开源/国产: llama.cpp/GGUF、bitnet.cpp、MNN、ncnn、ONNX Runtime Mobile。[3/3]
- **Benchmark 缺口:** 传统 MMLU/GSM8K/HumanEval/MathVista/MMMU 等仍有用, 但真实端侧体验需要 TTFT、tok/s、能耗、发热、后台稳态、任务完成率、抗中断、跨 App 成功率。Gemini 补充 OSWorld、AndroidWorld、MobileWorld 等 Agent benchmark, 但具体数字需核验。[3/3]

2. 标杆厂商

2.1 横向对比表

厂商	类型	代表端侧模型/能力	关键技术	落地产品功能	2025H2–2026 动态	端侧护城河	来源覆盖
Apple	OEM/芯片/OS	约 3B on-device foundation model; 服务端 PT-MoE	2-bit QAT、KV cache sharing/8-bit KV、LoRA、guided generation、tool calling、PCC、Core ML/MLX	Apple Intelligence、Foundation Models API、写作/摘要、Visual Intelligence、Live Translation	WWDC25 开放端侧 API; Siri 大升级时间存在冲突	芯片-OS-runtime-API-隐私闭环	[Claude+CL, Gemini有冲突]
Google	OEM/OS/模型	Gemini Nano; Gemma 3/3n/4; AICore	AICore、ML Kit GenAI API、LiteRT/LiteRT-LM、Private Compute Core	Pixel AI、TalkBack 图像描述、摘要/校对/改写、Gemma 开源生态	Pixel/Tensor G5、Gemini Nano 多模态、LiteRT 扩展	Android 平台控制权 + Gemini/Gemma 双生态	[3/3]
Samsung	OEM	Gauss2/ Galaxy AI/ Gemini 合作	Live Translate、Bixby、Agentic Builder、多模态 agents	Galaxy AI、通话翻译、Now Brief 等	S25 multimodal AI agents; S26/ Perplexity 仅 Claude 提到	全球高端机规模 + Qualcomm/ Google 合作	[Claude+CL]
Huawei	OEM/OS/芯片	Pangu/小艺; openPangu-Embedded-1B (边缘板, 非手机确认)	HarmonyOS、HMAF、HPIC/星盾、端云协同、A2A/MCP	小艺超级助理、GUI “帮忙”、修图、方言、多智能体	HarmonyOS 6、HMAF、80+ 智能体、天工计划 10 亿元	OS+芯片+本土生态闭环	[3/3, 参数核]

厂商	类型	代表端侧模型/能力	关键技术	落地产品功能	2025H2-2026 动态	端侧护城河	来源覆盖
vivo	OEM	BlueLM 1B/7B; 3B 端侧多模态/Agent 模型	BlueOS、Agent framework、本地知识图谱、VCAP/端侧加速	蓝心小 V、PhoneGPT、跨端共享、识屏/订餐/订咖啡	2025 开发者大会，开放 20+ 系统能力	端侧 Agent 和本土 Android 场景理解	[3/3]
Xiaomi	OEM/IoT/车	MiMo-7B、MiMo-VL-7B、MiMo-V2-Flash (Claude)	HyperOS/HyperAI、端侧加密记忆、人车家生态	超级小爱、帮记/找/填、圈屏、IoT/车联动	接入 DeepSeek-R1; 合作伙伴大会强调 AIOS	人车家全生态和快速产品化	[3/3, 模型自 Claude]
Honor	OEM	MagicLM/MagicGUI 7B; YOYO Agent	UI Agent、低 bit 量化、MagicOS、Agentic OS	3000+ 场景、4000+ 智能体、跨 App 执行	L3 认证、Robot Phone、MWC Agentic OS	GUI Agent 叙事和系统执行链领先	[3/3, 数字人]
OPPO	OEM	AndesGPT/安第斯; 记忆引擎; Gemini 称端侧 Omni	端侧记忆、A2A、端侧计算层、与 MediaTek 合作	小布 Agent、一键问屏/闪记、AI 影像/消除	Gemini 称 Find X9 端侧 Omni; ChatGPT 称技术公开度偏低	影像链路、系统资源控制、芯片联合调优、全球渠道	[3/3, Gemini 核]
Qualcomm	芯片/runtime	适配 Llama、Gemma、FastVLM 等	Hexagon NPU、AI Hub、QNN/QAIRT、ONNX Runtime Plugin EP	Android 高端机端侧 LLM/VLM、FastVLM	8 Elite/8 Elite Gen5, 0.12s TTFT、>11k prefill	高端 Android SoC 覆盖 + 工具链	[3/3]
MediaTek	芯片/runtime	D9400/APU890 或 D9500/NPU990	NeuroPilot、LiteRT、APU/NPU、on-device LoRA、BitNet?	Android OEM 端侧多模态/LLM	9400/9500 规格冲突，需核	高能效、与中国 OEM 深度合作	[3/3 冲突]
Microsoft/Windows	AI PC/OS/模型	Phi Silica、Foundry Local、Windows ML	NPU ≥40 TOPS、QNN/OpenVINO EP、离线模型	Recall、Live Captions、Cocreator、Click to Do	Copilot+ PC 从 Snapdragon 扩展 Intel/AMD	PC 端 8B+/长上下文/办公场景	[Claude+CLIP]

厂商	类型	代表端侧模型/能力	关键技术	落地产品功能	2025H2-2026 动态	端侧护城河	来源覆盖
Qwen/DeepSeek/Gemma/Phi/MiniCPM 等	模型厂商/开源	Qwen3、Qwen3-Omni、R1-Distill、Gemma 3n/4、Phi-4-mini、MiniCPM-V/o	hybrid thinking、MoE、蒸馏、多模态、长上下文、QAT	OEM/开发者端侧模型底座	2025H2-2026 开源小模型密集迭代	用更小 active footprint 做更强 agentic/multimodal	[3/3]

2.2 OEM 厂商补充

Apple

- 可确认核心：约 3B on-device model，2-bit QAT，KV cache 8-bit/共享，Foundation Models 框架，LoRA adapter，guided generation，tool calling，PCC。[Claude+ChatGPT]
- 争议点：Claude 版称 WWDC25 无新 Siri、Siri 大升级跳票；ChatGPT/Gemini 版称 WWDC26/next-gen Siri/iOS27 已发布或展示。正式稿需按最新官方发布核验。[冲突]
- 护城河：ANE、统一系统 API、隐私可信云、开发者入口、系统级上下文。

Google

- 主线：Gemini Nano 系统服务化 + AICore + ML Kit GenAI API + Gemma 开源外溢 + LiteRT/LiteRT-LM。
- 亮点：TalkBack 离线/弱网图像描述，Gemma 3/3n/4 多规格，Tensor G5 首发 Gemini Nano 相关能力。
- 风险：Android OEM 体验碎片化，Google 自有 Pixel 出货规模有限。

Samsung

- 主线：Galaxy AI 从功能包走向 AI companion / multimodal agents。
- 代表功能：Live Translate、通话翻译、Bixby/Now Brief、Gauss2 Compact/Balanced/Supreme。
- 风险：底层模型/API 透明度弱于 Apple/Google，自研模型与 Gemini/Qualcomm 合作之间定位需观察。

Huawei

- 主线：HarmonyOS + Pangu + 小艺 + HMAF + HPIC/星盾。
- 亮点：自有 OS 与终端闭环、隐私物理隔离叙事、小艺智能体平台。
- 存疑：手机内端侧模型参数、量化 bit、NPU TOPS 未充分公开；openPangu-Embedded-1B 更像 Ascend 边缘板模型，不宜等同手机内模型。

vivo

- 主线：BlueOS / BlueLM / 蓝心小 V / PhoneGPT / Agent framework。
- 亮点：3B 端侧 Agent 模型、20+ 系统能力、本地知识图谱、面向高频生活场景。
- 战略价值：可作为 OPPO 在中国 Android 阵营内的直接参考对象。

Xiaomi

- 主线：HyperOS/HyperAI/超级小爱/人车家。
- 亮点：端侧加密记忆、帮记/找/填、圈屏、IoT/汽车联动、MiMo 系列。
- 护城河：多设备、多入口、多生态场景；短板是底层模型/runtime 独占性仍需观察。

Honor

- 主线：YOYO Agent / MagicGUI / MagicOS / Agentic OS。
- 亮点：GUI Agent 执行链、跨 App 自动化、低 bit 量化、场景数量和生态智能体数量。
- 风险：真实成功率、耗时、第三方 App 改版鲁棒性、隐私权限争议。

OPPO

- 已有材料中较可靠的 OPPO 机会点：AndesGPT/安第斯、小布 Agent、端侧记忆引擎、A2A 路线、端侧计算层、AI 影像链路、与 MediaTek 深度合作。[Claude+ChatGPT]
- Gemini 版补充的“Find X9 端侧 Omni、多模态大模型、离线人像光影重构”等很有价值，但需要官方核验后再写入正式材料。[仅Gemini/需核]
- 建议内部表述：OPPO 不应只追“端侧最大模型”，而应突出 **端侧记忆 + 影像端侧化 + A2A 稳定主路径 + GUI 长尾兜底 + SoC 联合优化**。

2.3 芯片厂商与 AI PC 阵营

- **Qualcomm**：高端 Android 端侧 AI 最关键底座之一。关键词：Snapdragon 8 Elite/8 Elite Gen5、Hexagon NPU、AI Hub、QNN、QAIRT、ONNX Runtime Plugin EP、FastVLM、Llama/Gemma/Phi 等模型资产。[3/3]
- **MediaTek**：OPPO/vivo 等中国 Android OEM 的关键伙伴。材料中 D9400/APU890 与 D9500/NPU990 两套表述并存，需核规格；但方向明确：高能效 APU/NPU、NeuroPilot、LiteRT、端侧 LoRA、低 bit 支持、与 OEM 深度联调。[3/3 冲突]
- **Apple Silicon**：ANE + GPU Neural Accelerators + Core ML/MLX + Foundation Models，软硬闭环最强。[Claude+ChatGPT]
- **AI PC**：Copilot+ PC 把 NPU TOPS 门槛标准化；40+ TOPS 起步，Intel/AMD/Qualcomm 竞速；本地办公、长上下文、本地搜索、Recall/Live Captions 是核心场景。[Claude+ChatGPT]

2.4 当下值得关注的端侧小模型清单

模型	参数量/激活量	模态	亮点	可跑硬件/场景	覆盖
Apple on-device foundation model	约 3B	文本+图像理解/工具	2-bit QAT、KV cache、LoRA、系统 API	iPhone/iPad/Mac，封闭生态	[Claude+ChatGPT]

模型	参数量/激活量	模态	亮点	可跑硬件/场景	覆盖
Qwen3	0.6B-235B MoE	文本/推理	hybrid thinking/non-thinking, 中文强	手机/PC/云端分层	[3/3]
Qwen3-Omni-30B-A3B	30B/3B 激活	全模态	Thinker-Talker、音频/视频、低首包延迟	高端 PC/云/未来端侧探索	[Claude+ChatGPT+Gemini]
DeepSeek-R1-Distill	1.5B/7B/8B/14B/32B/70B	文本推理	大模型推理蒸馏，小模型 reasoning	1.5B/7B 端侧或 AI PC	[3/3]
Llama 3.2	1B/3B	文本	生态成熟，端侧基线	手机 NPU/CPU	[Claude]
Phi-4-mini / multimodal	3.8B	文本/多模态	长上下文、推理、桌面友好	8GB+ 设备/AI PC	[Claude+ChatGPT]
Gemma 3	270M/1B/4B/27B	文本/多模态	小规格到中规格，Google 生态	Android/PC	[3/3]
Gemma 3n E2B/E4B	有效约 2B/4B	多模态	低 RAM、多模态、LiteRT/AICore	Android 高端机	[3/3]
Gemma 4 E2B/E4B/12B/26B-A4B	多规格	多模态/音频	QAT、MTP、encoder-free/native audio 等	高端手机/PC，需核版本	[Claude+ChatGPT]
MiniCPM-V 4.5/4.6	约 1.3B	视觉语言	移动多模态强，iOS/Android/HarmonyOS 可跑	手机/Pad	[Claude+ChatGPT]

模型	参数量/激活量	模态	亮点	可跑硬件/场景	覆盖
MiniCPM-o 4.5	未定	全模态	全双工多模态直播，对标 Gemini 2.5 Flash	手机/Pad	[Claude]
SmolLM2/SmolLM3	135M-3B	文本	极小、多语、dual-mode reasoning	低端设备/嵌入式	[Claude+ChatGPT]
Ministral 3	3B/8B/14B	文本	edge family，企业端部署	手机/PC/边缘	[ChatGPT]
BitNet b1.58 2B4T	2B	文本	三值权重、极低内存/能耗	CPU/GPU/专用 kernel；量产需核	[Claude+Gemini]
MobileMoE-S/L	1.3B-5.3B 总，0.3B-0.9B 激活	文本	端侧 MoE Pareto 前沿	手机 CPU/GPU/NPU，需核	[仅Gemini]
EmbeddingGemma	300M	Embedding	端侧 RAG/本地检索	手机/端侧知识库	[Claude]

3. 用户需求

3.1 市场/调研数据

- **GenAI 手机快速普及：**Counterpoint AI 360 Service（2025-03-19）称 2025 年全球每三台出货手机就有一台具备 GenAI 能力，全年将超 4 亿台；2024 年为五分之一。[Claude+ChatGPT]
- **IDC 预测：**2024 年 GenAI 手机同比增 363.6% 至 2.342 亿台，占大盘 19%；2025 年预计同比增 73.1%；2028 年达 9.12 亿台，CAGR 78.4%；渗透率预计三年内超过 60%。[Claude]
- **Counterpoint 另一口径：**GenAI 手机全球累计出货 2025Q3 突破 5 亿台，正从高端下沉到中高端。[Claude]
- **Canalys/Omdia 口径：**AI 手机 2024 占 16%，2028 占 54%，2023-2028 CAGR 63%；中国厂商将在 2026 末-2027 推动中端普及。[Claude+ChatGPT]
- **中国市场：**信通院/IDC 预测 2026 国内 AI 手机出货 1.47 亿台、份额 >53%。[Claude]

- **AI 使用与隐私担忧**: YouGov 调查称 60% 消费者购机时看重 AI 功能，其中 21% “非常重要”；同调查中 60% 担心 AI 工具主要是企业收集更多数据。Deloitte 2025 Connected Consumer 中 24% 用户报告遇到数据隐私问题。[Claude+ChatGPT]
- **Agent 市场数据需核验**: Gemini 版称全球 AI Agent MAU 将从 2025-01 的 2 亿到 2026-12 的 5.3 亿，GUI Agent 从 200 万到 4900 万，中国份额从 29% 到 36%。该数据来自一份白皮书，建议作为“待核市场数据”。[仅Gemini/需核]

3.2 用户需求与价值主张

- **隐私/数据主权**: 用户希望银行交易、聊天记录、通话纪要、健康数据、相机画面等敏感数据不上传；PCC、Private Compute Core、HPIC/星盾、TEE 是对应技术叙事。[3/3]
- **低延迟/实时性**: 云往返 200–500ms 会破坏同传、AR 标注、通话助手、屏幕理解等体验；端侧要做到短上下文 token 级 <20ms 或至少主观“即时”。[Claude+Gemini]
- **弱网/无网可用**: 地铁、电梯、地下车库、飞机、隧道、海外漫游、偏远自驾等场景，需要 AI 不依赖云端。[3/3]
- **成本**: 端侧推理降低云 API 成本；Apple 本地模型被材料描述为 offline/privacy/free-of-cost，对开发者尤其重要。[ChatGPT]
- **续航/发热**: 快速耗电/热降频会杀死体验，推动更小模型、低 bit、bursty 推理、DVFS、NPU 专用优化。[3/3]
- **个性化与本地记忆**: 用户希望手机理解个人写作风格、日程、偏好、家庭/工作上下文，但不希望数据上云；端侧 LoRA、本地记忆、可清空记忆是关键。[3/3]
- **Agent 化代办**: 用户不再满足于问答，希望 AI “帮我把事办了”，包括跨 App 填表、报销、订票、订餐、总结、提醒、购物、设置手机等。[3/3]
- **无障碍/适老化**: 视障人群图像描述、老人语音导航、读谱、线下到店咨询 AI 手机等，是确定性且社会价值高的方向。[Claude+ChatGPT+Gemini]
- **自然多模态交互**: 说一句、拍一下、圈一下、问当前屏幕，AI 理解图文/语音/视频/屏幕状态并执行任务。[3/3]

3.3 杀手级场景

1. **实时翻译/离线同传/通话翻译**: Copilot+ Live Captions、iPhone Live Translation、Galaxy Live Translate、Gemma 3n E2B 实时语音翻译。[3/3]
2. **通话/会议助理**: 通话摘要、会议纪要、行动项提取、语音邮件摘要、Call Screening、防骚扰。[Claude+ChatGPT]
3. **本地相册/影像编辑与检索**: AI 消除、宠物影集、语义检索、端侧修图、暗光/逆光人像增强、视频高光提取、自动字幕。[3/3]
4. **屏幕理解与自动操作**: YOYO、PhoneGPT、豆包手机、超级小爱、小艺、Siri/Gemini/Pixel AI 通过当前屏幕和系统能力完成跨 App 任务。[3/3]

5. **本地知识问答与敏感数据处理**：本地文档、聊天记录、健康数据、财务数据、企业 BYOD 文档，本地分类/摘要/RAG，不出端。[Claude+ChatGPT]
 6. **无障碍视觉助手**：TalkBack/Gemini Nano、FastVLM、AR 眼镜/手机摄像头实时描述环境、公交牌、障碍物、红绿灯。[ChatGPT+Gemini]
 7. **智能通话反诈/AI 换脸检测**：在通话/视频中本地识别 AI 伪造、语音合成套路、诈骗脚本。[Gemini]
 8. **端侧个性化写作/回复**：本地 LoRA 学习用户语气、模板、常用表达，生成 Smart Reply 和工作文本。[Gemini+Claude]
 9. **车机/IoT 弱网语音管家**：在隧道/偏远自驾场景离线控制空调、车灯、导航、家庭 IoT。[Gemini+ChatGPT]
-

4. 相比 2025 旧材料的关键变化点

1. 旧材料“端侧计算 = 模型压缩 + 离线隐私”需要升级为“AIOS 系统工程”：2026 年竞争核心是 OS、NPU、runtime、系统 API、隐私云、Agent 执行、跨端上下文的整体闭环。[3/3]
 2. “3B/7B”口径需要重写：不是简单从 3B 到 7B，而是 sub-1B/1B-4B/8B+/云端 MoE 分层；3B 是主模型中心，1B 以下承担轻量任务，MoE/云端提升上限。[3/3]
 3. “量化重要”需改为“量化 + KV Cache + TTFT + 能耗稳态”：Apple 2-bit QAT、KV cache、MTP、投机解码、FastVLM 实测都说明端侧体验取决于全链路工程。[3/3]
 4. 新增“端侧 reasoning”一级方向：DeepSeek-R1 蒸馏、Qwen3 hybrid thinking、SmolLM3 dual-mode、Phi/Gemma/MiniCPM 等小模型后训练，应进入技术趋势页。[3/3]
 5. 端侧多模态从加分项变为标配：图像、音频、视频、屏幕内容理解逐渐成为系统模型预期能力。[3/3]
 6. GUI Agent 从概念变为厂商竞争主战场：荣耀、vivo、华为、小米、Apple、Google、Samsung 都在推进“屏幕理解 + 系统能力 + 工具/API 调用”。[3/3]
 7. 端云隐私从单点方案变为行业标准：Apple PCC、Google Private Compute Core/AICore、华为 HPIC/星盾、TEE/Private Processing，构成“端侧优先 + 私密云补位”。[3/3]
 8. 生态共建从原则变为具体平台战争：Foundation Models、AICore、LiteRT、QNN、NeuroPilot、ExecuTorch、ONNX Runtime、MNN/ncnn、Foundry Local 等是新材料必须写清楚的名字。[3/3]
 9. OPPO 自身机会应从“追模型参数”转向“端侧系统能力”：重点是端侧记忆、影像链路、权限/API 编排、A2A 与 GUI Agent 兜底、芯片微码/运行时联合优化。[Claude+ChatGPT+Gemini]
-

5. 矛盾与存疑清单

冲突/存疑点	三份材料说法	建议处理
Apple Siri / iOS 版本时间线	Claude: WWDC25 无新 Siri, Siri 大升级跳票; ChatGPT/Gemini: WWDC26 next-gen Siri/iOS27/Call Context	必须查 Apple 官方 newsroom/WWDC 页面后再写正式版
1.58-bit 是否已量产	Claude: MediaTek D9500 支持 BitNet 1.58; Gemini: 已跨过商用门槛; ChatGPT: 仍主要研究/实验, 未见主流 OEM 大规模披露	采用保守口径: “前沿, 需核实芯片/SDK/量产机型”
Dimensity 9400 vs 9500/9500s	ChatGPT/Gemini: D9400/APU890, 50 tok/s, -35% power, LoRA; Claude: D9500/NPU990, 100 TOPS, BitNet, UFS4.1	核对 MediaTek 官方规格和发布时间
DeepSeek V4-Flash	Gemini: 284B 总/13B 激活、1M context、本地强 Agent	仅 Gemini 提到, 来源需核, 不建议直接采用
Flash-MoE 400B on iPhone 17 Pro	Gemini: 12GB 设备跑 400B MoE, 0.6 tok/s	高度存疑, 只能写 “前沿探索/传闻”
OPPO Find X9 端侧 Omni	Gemini: Find X9 2026 搭载端侧 Omni, 多模态、离线人像光影重构	与 Claude/ChatGPT 的保守 OPPO 描述不一致, 需 OPPO 官方核验
Google I/O 2026 / Android 17 / Gemma 3 API 常驻	Gemini: Android 17 内置 Gemma 3 底层 API, Mariner Studio	需查 Google 官方 I/O/Android 文档
华为手机内模型参数/TOPS	Claude 明确说手机内参数/TOPS 未官宣; Gemini 给出更强 “星盾/盘古微内核” 表述	采用 Claude 保守口径, 避免把边缘板 openPangu 当手机内模型
“8-bit 被完全抛弃”	Gemini 如此表述; Claude/ChatGPT 均显示 AI PC/INT8 仍重要	Gemini 表述应删除或改写
OSWorld/AndroidWorld/MobileWorld 数字	Gemini 给 MAI-UI AndroidWorld 76.7%、MobileWorld 41.7%	需查 benchmark 官方榜单/论文
Agent 市场 MAU 数据	Gemini: AI Agent MAU 2亿→5.3亿, GUI Agent 200万→4900万	需核白皮书定义与统计口径
Honor YOYO 数字	Claude/Gemini: 3000+ 场景、4000+ 智能体、L3 认证、Robot Phone	建议查荣耀官方/信通院认证
Samsung S26 + Perplexity / Gauss 2.3	主要 Claude 提到	需核 Samsung 官方/可靠媒体
MNN/ncnn 2026 最新动态	Claude 明确说未取一手最新, ChatGPT 只作生态判断	需补国产 runtime 一手资料
iPhone 17 Live Translation 12 语言无网	Claude 提到	需查 Apple 官方机型/系统支持语言

冲突/存疑点	三份材料说法	建议处理
“用户需要低于 20ms 首字生成延迟”	Gemini 写“首字”；Claude 写“端侧短上下文每 token <20ms”	建议改成“token 级/交互级低延迟”，不要硬写首字 <20ms

6. 来源清单（压缩版）

三份原文已包含大量链接；这里保留适合正式材料继续核验的主来源名称与日期线索。

- Apple 《Intelligence Foundation Language Models Tech Report 2025》 / arXiv:2507.13575 / Apple Foundation Models / PCC / WWDC25-26
- Edge AI and Vision Alliance 《On-Device LLMs in 2026》 / 2026-01
- Vikas Chandra 《On-Device LLMs: State of the Union, 2026》
- Google Developers Blog: LiteRT、Qualcomm NPU、MediaTek NeuroPilot、Gemma/Gemini Nano/AICore
- Qualcomm 《Unlocking on-device generative AI》、Qualcomm AI Hub/QNN/QAIRT/ONNX Runtime Plugin EP
- MediaTek Dimensity 9400/9500 官方页面、NeuroPilot、LiteRT NPU 支持
- DeepSeek-R1 / DeepSeek-R1-Distill / HuggingFace 模型卡
- Qwen3 / Qwen3-Omni / QwenLM GitHub / arXiv
- OpenBMB MiniCPM-V / MiniCPM-o
- Microsoft Phi / Phi Silica / Copilot+ PC / Windows ML / Foundry Local
- PyTorch ExecuTorch 文档/论文
- llama.cpp/GGUF、bitnet.cpp、BitNet b1.58 2B4T
- KIVI、KVQuant、KVTuner、MixKVQ、RotateKV、TurboQuant、Kitty、 “Don’ t Waste Bits!”
- Counterpoint AI 360 Service、IDC Worldwide Generative AI Smartphone Forecast、Canalys/Omdia、Deloitte Connected Consumer、YouGov Surveys
- 荣耀 MagicGUI/YOYO、vivo BlueOS/PhoneGPT、华为 HMAF/小艺/HPIC、小米 HyperOS/超级小爱、OPPO AndesGPT/小布/记忆引擎/MediaTek 合作材料