

业务机会点四：端侧计算 / On-Device LLM —— 面向 2026 的全面更新与扩充（原始素材库）

本文为「二次提炼」准备的原始素材库，刻意求全求细、不避冗长重复。可信度标注：**【已确认】**=官方/论文/权威媒体可查；**【预期/传闻】**=供应链/发布会前/未官宣；**【推测】**=分析推断。检索窗口以 2025H2-2026 为主，当前日期 2026-06-24。每条尽量附来源+时间。

一、技术趋势

1. 端侧模型能力与规模

- **【已确认】**端侧主流参数区间已从旧材料"7B 为底"显著分层下探，并通过 MoE 实现"大容量小激活":
 - sub-1B: SmolLM2 (135M-1.7B)、Gemma-3 270M、Qwen2.5 (0.5B/1.5B) ;
 - 1-4B: Llama 3.2 (1B/3B)、Phi-4-mini (3.8B)、Gemma-3n E2B;
 - 端侧 MoE: Gemma 4 26B-A4B (激活 4B) 在消费级硬件 85 tok/s。
 - 来源: Edge AI and Vision Alliance 《On-Device LLMs in 2026》2026-01; v-chandra.github.io 《On-Device LLMs: State of the Union, 2026》; Pinggy 2026。
- **【已确认】**关键工程共识: decode 阶段是**内存带宽瓶颈**而非算力瓶颈 (每生成一个 token 需流式读取全部权重), 故压缩 (16→4 bit 即 4× 减少每 token 内存流量) 影响被放大; 手机 OS 开销后实际可用 RAM 常 <4GB, 限制了模型大小与 MoE 选择。来源: Edge AI and Vision Alliance 2026-01。
- **【已确认】**Apple 端侧基础模型 ~3B: 2-bit QAT + KV-cache 共享, 分两块 (Block1 含 62.5% transformer 层, Block2 含 37.5% 且去掉 K/V 投影), KV cache 内存降 37.5%、TTFT 降约 37.5%; tokenizer 由 10 万扩到 15 万词表支持 16 语言。来源: Apple 《Intelligence Foundation Language Models Tech Report 2025》arXiv:2507.13575, 2025-07。
- **【已确认】**端侧 MoE 落地: MediaTek Dimensity 9500 NPU 990 支持 3B LLM 输出翻倍、128K 长文; 端侧 Gemma-3n E2B 在 D9500 (vivo X300 Pro) 上 prefill >1600 tok/s、decode 28 tok/s (4K 上下文), NPU 较 CPU 12×、较 GPU 10×。来源: Google Developers Blog 2025-12; MediaTek 2025-09-22。
- **【已确认】**端侧推理 (reasoning) 模型成熟: Qwen3 全系 (0.6B-235B MoE) 引入 hybrid thinking/non-thinking 模式; Qwen3-4B 可媲美 Qwen2.5-72B-Instruct, Qwen3-30B-A3B 超越激活参数 10× 的 QwQ-32B。来源: Ollama qwen3; MindStudio。
- **【已确认】**端侧全模态: Qwen3-Omni-30B-A3B (MoE, 30B 总/3B 激活) Thinker-Talker 架构 + AuT 预训练 + 多码本设计, 冷启动端到端首包延迟理论 234ms, 36 个音频/视频基准 32 个开源 SOTA、22 个总 SOTA; 支持 119 文本/19 语音输入/10 语音输出语言。来源: arXiv:2509.17765; QwenLM GitHub。
- **【已确认】**端侧多模态小模型: MiniCPM-V 4.6 仅 1.3B 跑赢 Gemma4-E2B (OmniDocBench 84.6 vs 47.0; HallusionBench 幻觉率 30.6% vs Qwen3.5-0.8B 41.7%), iOS/Android/HarmonyOS 可跑, Apache 2.0; Thinking 变体在 MathVista

75.6/MMMU 55.3; MiniCPM-o 4.5 (2026-02-03) 对标 Gemini 2.5 Flash, 支持全双工多模态直播。来源: OpenBMB MiniCPM-V GitHub; NYU Shanghai RITS; firethering 2026。 (Firethering + 3)

- 【已确认】Matryoshka/弹性思路体现于 Gemma 3n (MatFormer/嵌套子模型, 可弹性取 E2B/E4B) 与 ParetoQ (≤ 2 -bit 学到根本不同表示)。来源: Edge AI and Vision Alliance 2026; (注: Gemma 3n MatFormer 细节因检索预算耗尽未取到一手官方页, 标记需复核)。

2. 数据蒸馏 & 模型蒸馏

- 【已确认】DeepSeek-R1 蒸馏六款 dense 模型 (1.5B/7B/8B/14B/32B/70B, 基于 Qwen2.5 与 Llama3), 用 R1 生成的 **80 万条推理样本仅做 SFT (无 RL 阶段)**; R1-Distill-Qwen-1.5B 在 AIME2024/MATH-500 上超过 GPT-4o 与 Claude-3.5-Sonnet; R1-Distill-Qwen-32B 在多基准超 o1-mini。结论: 把强模型蒸馏到小模型优于小模型直接做大规模 RL。来源: HuggingFace deepseek-ai/DeepSeek-R1 (2025-01); DataCamp; deepseekai.guide。 (Medium) (arxiv)
- 【已确认】Apple ~3B 端侧模型训练大量用高质量合成数据 + 责任式网络爬取 + 授权语料。来源: Apple Tech Report 2025。
- 【已确认】小模型能力更多由数据质量/蒸馏驱动而非纯参数; distilled 小模型在数学/推理上可超大数倍 base 模型。来源: Edge AI and Vision Alliance 2026-01。

3. 预训练 & 后训练

- 【已确认】Apple 用全新**异步平台**做 SFT + RL; Foundation Models 框架开放 LoRA adapter 微调 (Python 工具包) + guided generation + constrained tool calling。来源: Apple Tech Report 2025。
- 【已确认】hybrid thinking 训练: Qwen3 单模型快/慢思考切换; 荣耀 MagicGUI 用两阶段范式 = 继续预训练 (CPT, 注入 GUI 知识提升屏幕感知/定位) + 强化微调 (RFT, 引入空间增强复合奖励函数与 DF-GRPO 算法)。来源: Ollama; 每日经济新闻 2025-07-26。
- 【已确认】DeepSeek-R1-Zero 纯 RL 无 SFT 即涌现自验证/反思, 但有重复/可读性/语言混杂问题; R1 加 cold-start SFT 再 RL 改善。来源: HuggingFace DeepSeek-R1。 (Hugging Face)

4. 量化 (重点)

- 【已确认】**2-bit 已真正量产落地**: Apple ~3B 端侧模型用 2-bit QAT (量产于 iOS/iPadOS/macOS 26, 2025-09)。来源: Apple Tech Report 2025。
- 【已确认】**1.58-bit 原生进芯片**: MediaTek D9500 NPU 990 引入 BitNet 1.58-bit 大模型处理, 功耗降最高 33%。来源: MediaTek 2025-09-22。
- 【已确认】BitNet b1.58 2B4T (微软, 2025-04) 首个开源原生 1-bit (三值 $\{-1, 0, +1\}$, 激活 8-bit, FFN 用 squared ReLU 增稀疏), 2B 参数/4T tokens, 性能比肩同规模全精度; bitnet.cpp 上能耗降 55.4%-70% (但官方称未建议直接商用, 且加速仅在 bitnet.cpp 专用 kernel 上)。来源: arXiv:2504.12285; microsoft/BitNet GitHub。 (InfoQ + 3)

- 【已确认】高通 Hexagon 自骁龙 8 Gen 2 起原生 INT4，INT4 层张量吞吐翻倍；8 Gen 3 NPU 较前代快 98%、每瓦性能 +40%。来源：Qualcomm 《Unlocking on-device generative AI》白皮书。
- 【已确认】KV Cache 量化：KIVI (ICML24) 免微调非对称 2-bit (key 按 channel、value 按 token)，峰值内存降 2.6 倍、batch 可大 4 倍、吞吐升 2.35-3.47 倍，启发了 HuggingFace Transformers KV cache 量化；2-bit KIVI 在推理任务掉点明显（如 R1-Distill-Llama-8B KV2 均分从 BF16 53.77 降至 43.11），催生 KVTuner（逐层混合精度）、MixKVQ (query-aware)、RotateKV、KVQuant (pre-RoPE key 量化+稀疏离群) 等。来源：jy-yuan/KIVI GitHub；arXiv:2512.19206、2511.18643。 (GitHub + 2)
- 【已确认】PTQ 系 (GPTQ/AWQ) 保留多数质量降 4 倍内存；离群激活由 SmoothQuant/SpinQuant/QuaRot (正交旋转) 处理；ParetoQ 发现 ≤ 2 -bit 时模型学到根本不同表示而非简单压缩。AWQ 为硬件友好的纯权重低 bit。来源：Edge AI and Vision Alliance 2026-01；arXiv 综述。
- 【已确认】Copilot+ PC 端侧普遍走 INT8 (40 TOPS 即按 INT8 计)；FP32→INT8 约 4× 提速、精度损失小。来源：Microsoft Learn；Oreate AI 2026。

5. 权重稀疏化 / 剪枝 / 激活稀疏

- 【已确认】非结构化剪枝 (SparseGPT、Wanda) 可达高稀疏率但需稀疏矩阵支持；结构化剪枝 (删整 head/layer) 在标准移动硬件上跑得快。来源：v-chandra.github.io 2026。
- 【已确认】激活稀疏研究线：R-Sparse (rank-aware activation sparsity)、CHESS (channel-wise thresholding + selective sparsification)、ReLU 复兴 (Mirzadeh et al. "ReLU Strikes Back" ICLR24)、PowerInfer (消费级 GPU 利用激活稀疏)；TEAL/ProSparse/Deja Vu 属同一"以稀疏换速度/省内存"方向。来源：arXiv:2504.19449、arXiv:2409.01366。

6. 推理加速

- 【已确认】投机解码主流两路：Medusa (Princeton, 加多解码头并行预测, 2.2-3.6× 加速, 仅训新头)、EAGLE (外推 hidden state 特征无需微调目标模型, EAGLE-3 融合低/中/高层语义)，均已集成进 vLLM/TensorRT-LLM；Intel+Weizmann (ICML25) 任意小草稿模型加速任意 LLM (跨词表)，最高 2.8×。端侧因常已有小模型可作草稿而尤为契合。来源：v-chandra.github.io 2026。
- 【已确认】MediaTek D9500s 集成 Speculative Decoding+ (SpD+)；Gemma 4 用 Multi-Token Prediction (MTP) drafter 降延迟。来源：MediaTek 规格；Pinggy 2026。
- 【已确认】扩散式并行解码 (LLaDA、SBD、TiDAR) 以去噪方式并行预测多 token，结合投机解码有望 4-6× 加速，端侧潜力大但尚不成熟。来源：v-chandra.github.io 2026。
- 【已确认】端侧首 token/吞吐实测：FastVLM-0.5B (int8 权重 + int16 激活) 在骁龙 8 Elite Gen 5 (小米 17 Pro Max) NPU 上对 1024×1024 图 TTFT 仅 0.12s、prefill >11,000 tok/s、decode >100 tok/s；LiteRT QNN 上 72 个模型 64 个可全量委派 NPU，56 个 <5ms。来源：Google Developers Blog (Unlocking Peak Performance on Qualcomm NPU with LiteRT)。
- 【已确认】Snapdragon 8 Elite 端侧实测 (Llama 3.2 3B ~10 tok/s、Llama 3.1 8B ~5 tok/s, 全跑 NPU)；老芯片 8 Gen 1 (Hexagon v69) 经社区可达 31 tok/s (OnePlus 10 Pro)。来

源: Grapeup; avisre/snapdragon-npu-llm GitHub。

7. 模型架构创新

- 【已确认】混合架构 (Mamba/SSM + attention) 获牵引以低延迟处理长上下文: Qwen3 Next、Nvidia-Nemotron3; Qwen Gated Delta-Net、DeepSeek mHC (Manifold-Constrained Hyper-Connections) 显示对纯 attention 的改进。RWKV/线性注意力/Jamba/Zamba 属同类方向。来源: v-chandra.github.io 2026。
- 【已确认】细粒度 MoE/共享专家: Apple 服务端 PT-MoE (Parallel-Track MoE, track 并行 + 稀疏 MoE + 全局-局部交错注意力); 端侧 Gemma 4 26B-A4B; Qwen3-Omni Thinker-Talker MoE。来源: Apple Tech Report 2025; Pinggy 2026。
- 【已确认】Gemma 4 12B (2026-06-03) encoder-free 多模态: 视觉走单次矩阵乘、原始音频直投入文本 token 维度, 全进 LLM 主干; 首个中尺寸 Gemma 原生音频输入。来源: Pinggy 2026。

8. 长上下文 / 端侧个性化 / 端侧隐私

- 【已确认】端侧长上下文: D9500 支持 128K; Qwen3.5 端侧 32K (量化版实际 8-16K, 3GB 模型可载入 iPhone 15 Pro 的 8GB RAM)。来源: MediaTek; MindStudio。
- 【已确认】端侧个性化 = 端侧 LoRA + 本地记忆: Apple 部署 LoRA 适配器 (旧材料"部署上百个 LoRA"已被官方框架兑现); OPPO「记忆引擎」端侧化, 提出五特性 (安全隐私/即插即拔/主动推理/自动更新/端云结合), 并指出 32B 模型压缩到手机要占 16GB 内存是核心难点 (其判断 2-3 年解决); 小米超级小爱端侧加密记忆、可清空。来源: Apple Tech Report; 知乎《OPPO 姜昱辰》2026; AIHub 超级小爱。
- 【已确认】端云隐私三件套: Apple Private Cloud Compute (用后不留、Apple 不可见、可第三方验证); Google AICore 遵循 Private Compute Core (无直接联网、请求隔离、用后不存); 华为 HPIC (HarmonyOS Personal Intelligent Computing, "算完即删")。来源: Apple; Android Developers; C114 2025-10。
- 【已确认】联邦学习 + TEE 被业内视为端云协同隐私基础设施。来源: 羊城晚报 MWC2025 (项立刚)。

9. 端侧 Agent

- 【已确认】GUI Agent 成竞赛主战场。荣耀 MagicGUI (7B, WAIC2025 开源, CPT+RFT) 驱动 YOYO 跨 App (滴滴/高德/美团) 打车点咖啡; YOYO 2025-10 获信通院 **L3 级认证**, 支持 3000+ 场景自动执行、接入 4000+ 生态智能体, 新增视频通话卡路里识别等; 2025-12-08 部署于 ROBOT PHONE (计划 2026H1 量产)。来源: 每日经济新闻 2025-07-26; 百度百科 YOYO。
- 【已确认】vivo PhoneGPT (蓝心小V, 识屏+接管音频自主对话完成订餐订咖啡); 2025 vivo 开发者大会称全球首个专为端侧 Agent 构建的 3B 量级模型, 并建本地化知识图谱构建"人与设备共同记忆"。来源: 智东西; 腾讯新闻 2025-10-11。
- 【已确认】字节联合中兴**豆包 AI 手机** (2025-12 工程样机, 首批 3 万台秒罄, 二手溢价 >3500 元), 系统级 GUI Agent 越过应用沙盒直接读屏点屏。来源: 量子位 2026-05。

- 【已确认】华为 HMAF (鸿蒙智能体框架) + 小艺智能体开放平台四模式 (操控/伴随/GUI 任务/任务协同, A2A+MCP, 首批 80+ 智能体); "鸿蒙天工计划"10 亿元激励。来源: Leiphone; GeekPark 2025-09。
- 【已确认】实现机制现状: 多依赖安卓"无障碍权限"识屏+模拟点击 (荣耀/小米/三星 Bixby 实测会开启), 引发隐私争议; OPPO 倾向 A2A 接口而非 GUI 路线, 视 GUI 为长尾兜底。成功率低、响应不稳、耗时长仍是普遍问题, 仅 YOYO 接近"半托管"。来源: 21世纪经济报道 2025-01/03。 (21st Century Business Herald)

10. 端侧专用芯片 / NPU

- 【已确认】高通: 骁龙 8 Elite 双 Hexagon NPU 核, AI 性能快 45%, 新增 Scalar/Vector 核 (8+6), Sensing Hub +60% AI 性能; 骁龙 8 Elite Gen 5 支撑 FastVLM 0.12s TTFT; 骁龙 X Elite NPU 45 TOPS (INT8), 可跑 13B+; AI ISP 支持 4K60 实时 AI。来源: Android Faithful; Qualcomm; Google Dev Blog。
- 【已确认】联发科: D9500 (2025-09-22, 3nm, All Big Core 4.21GHz) NPU 990 + GenAI Engine 2.0 算力翻倍、**100 TOPS NPU**、BitNet 1.58、首个 compute-in-memory Super Efficient NPU、4 通道 UFS4.1 使大模型加载快 40%; D9500s (2026-01-15)。来源: MediaTek 2025-09-22; CyberRaiden 2026-03。
- 【已确认】Apple A19/A19 Pro (2025-09, TSMC N3P): 16 核 Neural Engine (带宽提升) + GPU 内嵌 Neural Accelerators (A19 Pro 峰值算力 4× A18 Pro); A19 Pro 12GB LPDDR5X-9600、76.8GB/s; vapor chamber 使持续性能 +40%, 官方称"本地生成与大模型跑得更快"; 第三方 (Argmax) 指出 ANE 仍是端侧大规模推理首选 (能效/原生压缩加速/峰值吞吐)。来源: Apple newsroom 2025-09; Wikipedia A19; Argmax。 (Fandom) (Apple)
- 【已确认】PC/AIPC: Copilot+ 门槛 NPU ≥40 TOPS (INT8); 高通骁龙 X (Hexagon ~45 TOPS)、Intel Core Ultra 200V (NPU 48 TOPS+)、AMD Ryzen AI 300 (XDNA, HX 370 NPU 50 TOPS)。来源: Microsoft Learn; Oreate AI 2026。 (Microsoft Learn)
- 【已确认】华为 Kirin 9020 (Mate 70, SMIC 7nm, 达芬奇 NPU, 官方未公布 TOPS); Mate 80 系列 (2025-11-25) 首发 Kirin 9030。来源: GSMArena; 21经济网 2025-11。【预期/传闻】Kirin 9030 NPU ~31 TOPS、可能独立 NPU 协处理器, 未官宣。来源: icviews.cn。 (21st Century Business Herald)

11. 端云协同 (Hybrid AI)

- 【已确认】Apple 默认端侧、需更高算力时路由到 PCC。Google AI Core 端侧 Gemini Nano, 复杂/长上下文/联网知识回退 Gemini Pro (开发者用 Coordinator 模式做按难度路由)。荣耀 YOYO Claw "端云协同、端侧优先", 简单任务端侧、复杂走云, PC 端综合 Token 消耗较社区版 OpenClaw 降约 50% (荣耀官方披露)。华为/vivo/OPPO 均强调"端侧优先 + 加密上云"。来源: Apple; Medium Jibify; 量子位 2026-05; 21经济网。
- 【已确认】按难度/隐私分级路由成范式: 日常格式化/轻问答/摘要在端, 前沿推理/长对话在云。来源: Edge AI and Vision Alliance 2026。

12. 端侧推理框架 / 运行时

- 【已确认】ExecuTorch (50KB footprint, 移动部署)、llama.cpp/GGUF (CPU/原型)、

- MLX (Apple Silicon, 较 llama.cpp 快 20-50%) 三足并立; bitnet.cpp (1-bit 专用, 基于 llama.cpp 与 T-MAC LUT) 。来源: Edge AI and Vision Alliance 2026; localaimaster。
- 【已确认】Google LiteRT + MediaTek NeuroPilot Accelerator (2025-12 发布, 替代旧 TFLite delegate, 统一 Compiled Model API, 支持 AOT + 端侧编译) , 生产级支持 Qwen3-0.6B、Gemma-3-270M/1B/3n-E2B、EmbeddingGemma-300M; 覆盖 D7300/8300/9000/9200/9300/9400。LiteRT QNN 在骁龙 8 Elite Gen 5 上 NPU 较 CPU 最高 100×、较 GPU 10×。来源: Google Developers Blog 2025-12; MediaTek 博客。
 - 【已确认】高通 QNN (AI Engine Direct) /Genie/AI Hub + ONNX Runtime (提供 Llama-3.2-3B Hexagon NPU 资产) ; Nexa SDK 在骁龙 X Elite NPU 跑 OmniNeural-4B (唯一本地多模态)、Qwen3-4B-Thinking、Phi4-mini、Llama-3B。来源: ONNX Runtime 文档; XDA 2025。
 - 【已确认】Android AICore 系统服务统一分发/更新 Gemini Nano, ML Kit GenAI API 提供摘要/校对/改写/图像描述/语音识别。来源: Android Developers。
 - 【已确认】阿里 MNN、腾讯 ncnn、ONNX Runtime Mobile、面壁 MiniCPM (端侧框架协同) 仍为国产端侧栈主力 (本轮检索预算耗尽未取一手最新动态, 标记需复核) 。

13. 端侧评测基准

- 【已确认】通用: MMLU/MMMLU/MGSM (Apple 用) 、HumanEval; 推理: AIME 2024/2025、MATH-500、GPQA-Diamond、LiveCodeBench、CodeForces; 多模态: MathVista、MMMU、HallusionBench、OmniDocBench。来源: Apple Tech Report; firethering MiniCPM-V; arXiv 多篇。
- 【已确认】端侧"测速"基准多由厂商/社区自测 (tok/s、TTFT、NPU 利用率) , 如 Argmax iPhone 17 基准、llama.cpp Snapdragon X 讨论帖。来源: Argmax; GitHub。

二、标杆厂商

A. 手机/终端厂商 (OEM) 横向对比

厂商	端侧模型 (名称/参数)	关键技术	落地产品/功能	2025H2-2026 最新动态	端侧护城河/优劣
Apple	端侧 ~3B Foundation Model; 服务端 PT-MoE	2-bit QAT、KV-cache 共享、LoRA、guided generation、tool calling、PCC	Apple Intelligence、Foundation Models 框架、写作/通知摘要/Image Playground、Visual Intelligence、Live Translation	WWDC25 开放端侧 API; iOS26 (2025-09) 落地; Siri 大升级跳票 (WWDC25 无新 Siri)	系统级 I/O、ANE 能效、隐私 PCC; 劣势: Siri 滞后、国行 AI 功能受限

厂商	端侧模型（名称/参数）	关键技术	落地产品/功能	2025H2-2026 最新动态	端侧护城河/优劣
(12 语言离线)					
Google	Gemini Nano（Nano-1 ~1.8B/Nano-2 ~3.25B, Pixel 10 用 nano-v3）	AICore、Private Compute Core、ML Kit GenAI API、LoRA adapter	Pixel；摘要/校对/改写/图像描述/语音识别	Gemini Nano 多模态随 Pixel 10； LiteRT NeuroPilot（2025-12）	安卓系统级 + 跨芯片；劣势：Pixel 量小
Samsung	Gauss2 三档（Compact 端侧/Balanced/Supreme）	自研 tokenizer、知识图谱、Agentic Builder	Galaxy AI、端侧翻译、Bixby	Gauss 2.3/2.3 Think/O Flash + Agentic Builder； S26 引入 Perplexity； 9-14 语言、速度快 1.5-3×	出货规模大；劣势：S24 曾改用 Gemini，自研落地慢
Huawei	小艺基于 Pangu L0→L1； openPangu-Embedded-1B（边缘板）	端云协同、HMAF、HPIC"算完即删"、GUI"帮忙"	HarmonyOS 6（2025-10-22, Mate80/X7 首发）、系统级超级助理小艺、对话式修图、16+ 方言	HMAF + 智能体平台（80+）、天工计划 10 亿元；端侧 NPU 修图约 2s 启动	自研 OS+芯片闭环；劣势：手机内端侧模型参数/TOPS 未官宣
vivo	蓝心 BlueLM（1B/7B 端侧； 70B/130B/175B 云）； 3B 端侧多模态推理	端侧 Agent、本地知识图谱、语音/图像/多模态大模型	OriginOS 6、蓝心小V、PhoneGPT	2025 聚焦 3B（占 2GB 内存 vs 旧 7B 占 3.5GB），全球首个端侧 Agent 3B 模型	高频场景执行、无障碍/适老；劣势：语义部分依赖百度合作
Xiaomi	MiMo-7B（端侧推理）、MiMo-VL-7B、MiMo-V2-Flash（309B/15B 激活 MoE, 2025-12-16 开源）	HyperOS 端侧加密记忆、人车家全生态、端云混合	超级小爱（系统级，帮记/找/填）、接入 DeepSeek-R1（2025-02）	MiMo-V2 系列（Pro/Omni/TTS）； 玄戒 O1 自研芯片； AI 日均使用 2 亿次	生态规模 + 开源；劣势：海外隐私合规、模型中立性

厂商	端侧模型（名称/参数）	关键技术	落地产品/功能	2025H2-2026 最新动态	端侧护城河/优劣
Honor	MagicLM 端云矩阵； MagicGUI 7B（开源）	与高通联合端侧低 bit 量化（省 30% 存储/提速 15%）、 Magic Agent	YOYO（L3 认证、3000+ 场景、4000+ 智能体）、 Robot Phone	MWC上海2026 定义 Agentic OS （2026-07 完整框架， MagicOS 11）	GUI Agent 领先、端云优先路由；劣势：成功率/稳定性
OPPO	AndesGPT/安第斯	端侧记忆引擎、A2A、 端侧计算层	小布 Agent、 ColorOS	重投"记忆"赛道，倾向 A2A 而非 GUI	记忆系统/隐私端侧化；劣势：执行链路保守

补充：

- 【已确认】Apple 端侧模型在 MMLU/MMMLU 上胜 Qwen-2.5-3B、Gemma-3-4B，竞争 Qwen-3-4B；安全性（CyCraft 测）prompt injection 拦截 70.4% 优于 Qwen3-4B/Llama-3.2-3B/GPT-4.1-nano。来源：emergentmind；CyCraft 2025-06。
- 【已确认】华为 openPangu-Embedded-1B（2025-09，~1B、26 层、10T tokens、32K，MMLU 60.72%/HumanEval 56.71%，Atlas 200I A2 上 ~0.156s/token），但面向 Ascend 边缘板，**非确认为手机内模型**。来源：Tencent News 2025-09-05。[GitHub](#) [Tencent News](#)
- 【已确认】小米 MiMo-V2-Flash 在多个 Agent 基准进全球开源 Top2，代码能力超所有开源、比肩 Claude 4.5 Sonnet，推理成本仅其 2.5%、速度 2×。来源：腾讯云开发者社区 2025-12-17。

B. 芯片厂商（详见 §10）

高通（骁龙 8 Elite / 8 Elite Gen 5、Hexagon、AI Hub、Genie）、联发科（D9500/9500s、NPU 990、NeuroPilot Gen-AI SDK）、Apple（ANE + GPU Neural Accelerators）、Google Tensor G5、NVIDIA（Jetson/边缘）、Intel（Core Ultra 200V，NPU 48 TOPS+）、AMD（Ryzen AI 300，XDNA，50 TOPS）。

C. 模型厂商 / 开源端侧小模型清单

模型	参数	模态	亮点	可跑硬件
Qwen3	0.6B-235B(MoE)	文本	hybrid thinking	手机/PC (0.6B 端侧 NPU)
Qwen3-Omni-30B-A3B	30B/3B 激活	全模态	234ms 首包、32 SOTA	高端 PC/服务端

模型	参数	模态	亮点	可跑硬件
Qwen3.5	4B/8B	文本	端侧优化、32K	iPhone/Android/旧笔记本
DeepSeek-R1-Distill	1.5/7/8/14/32/70B	文本推理	1.5B 超 GPT-4o(数学)	视参数, 1.5B 可端侧
Llama 3.2	1B/3B	文本	生态最大	手机 NPU/CPU
Phi-4-mini	3.8B	文本/多模态	小模型最强推理	8GB 设备 ~15-20 tok/s
Phi Silica	~3.3B 级	文本	NPU 量化、Copilot+ 内置	Copilot+ PC NPU
Mistral Ministral / Small 3	3B/8B/7B	文本	指令跟随快	笔记本/手机
GLM-Edge	端侧档	文本	智谱端侧	手机/PC
MiniCPM-V 4.6	1.3B	多模态	跑赢 Gemma4-E2B	iOS/Android/HarmonyOS
MiniCPM-o 4.5	—	全模态	对标 Gemini 2.5 Flash、全双工	手机
SmolLM2	135M-1.7B	文本	极小	任意
Gemma 3	270M/1B/4B/27B	多模态	270M 易微调、4B 多语种	手机 NPU
Gemma 3n E2B	~2B 有效	全模态	MatFormer、音视频	D9500 28 tok/s
Gemma 4	12B/26B-A4B	多模态	encoder-free、native audio	16GB RAM/消费级
BitNet b1.58 2B4T	2B	文本	原生 1-bit、CPU 0.4GB	CPU/NPU(bitnet.cpp)
EmbeddingGemma	300M	嵌入	端侧 RAG/检索	手机

D.PC / AI PC 阵营

- 【已确认】微软 Copilot+ PC：NPU ≥40 TOPS；Phi Silica 端侧 SLM（纯 NPU 运行，离线），驱动 Recall、Live Captions（40+ 语言→英文，离线）、Cocreator、Click to Do；Phi Silica 已从骁龙扩展至 Intel（KB5079266，Win11 26H1）/AMD；开发栈 Foundry Local + Windows ML（自动选 EP：QNN/OpenVINO，失败回退 GPU/CPU）。最低配 16GB RAM/256GB SSD。来源：Microsoft Learn；windowsnews.ai 2025–2026。

- 【已确认】Copilot+ 设备早期占出货少数；NPU 三方竞速：Qualcomm 骁龙 X（先发）、Intel Core Ultra（48 TOPS+）、AMD Ryzen AI。来源：Windows Forum；Oreate AI 2026。
-

三、用户需求（2026 更新）

市场数据

- 【已确认】据 Counterpoint Research AI 360 Service（2025-03-19）：2025 年全球每三台出货手机就有一台具备 GenAI 能力，**全年将超 4 亿台**（2024 年为五分之一/one in five）。来源：Counterpoint。 (Counterpoint)
- 【已确认】据 IDC《Worldwide Generative AI Smartphone Forecast, 2024-2028》（2024-07, Doc #US52412224）：2024 年 GenAI 手机同比增 363.6% 至 **2.342 亿台、占大盘 19%**；2025 年预计同比增 73.1%；**2028 年达 9.12 亿台、CAGR 78.4%**；IDC 资深研究总监 Nabila Popal 称渗透率"预计三年内超过 60%"。来源：IDC。 (IDC)
- 【已确认】据 Counterpoint Research（分析师 Ibrahim Abbas）：GenAI 手机**全球累计出货 2025Q3 突破 5 亿台**，正从高端下沉到中高端。来源：Counterpoint。
- 【已确认】Canalys/Omdia：AI 手机 2024 占 16%→2028 占 54%（2023-2028 CAGR 63%）；普及由中国厂商（小米/OPPO/vivo/荣耀）2026 末-2027 推向中端驱动。来源：Omdia/Canalys。 (Omdia)
- 【已确认】中国市场：信通院/IDC 预测 2026 国内 AI 手机出货 1.47 亿台、份额 >53%。来源：网易科技 2026。 (NetEase)
- 【已确认】2026Q1 全球手机出货同比 -6%（DRAM/NAND 短缺涨价 + 需求疲软），苹果首次拿下 Q1 第一。来源：Counterpoint 2026。 (Counterpoint)

需求与价值主张

- 【已确认】四大核心驱动：**延迟**（云往返 200-500ms，端侧短上下文每 token <20ms）、**隐私**（数据不出端，对健康/财务敏感数据尤关键）、**成本**（端侧推理零云端费）、**可用性**（弱网/无网/隧道/地库）。来源：v-chandra.github.io 2026；Edge AI and Vision Alliance。
- 【已确认】据 YouGov Surveys（2024-09-23/24，美国 1,221 名成人）：**60% 消费者购机时看重 AI 功能，其中 21% 视为"非常重要"**；同调查中 60% 担忧 AI 工具主要是企业借机收集更多用户数据。来源：YouGov（经 Remindax 引用）。
- 【已确认】隐私焦虑实证：据 Cisco《2025 Data Privacy Benchmark Study》（2025-04-02，12 国 2,600+ 隐私与安全专业人士）"64% 担心无意中把敏感信息泄露给公众或竟对"（注：受访者为专业人士非普通消费者）；Forrester 2025 指消费者对 AI 信任度低且受隐私人格影响；Deloitte 2025 Connected Consumer（约 3,500 美国消费者）24% 报告遇到数据隐私问题。来源：Cisco；Forrester；Deloitte。 (Cisco + 2)
- 【已确认】功耗/续航是产品生死线：快速耗电/热降频会"杀死产品"，推动更小量化模型 + bursty 推理（快完快回低功耗）。来源：v-chandra.github.io 2026。
- 【已确认】个性化/主动式/预测式：从"人找服务"到"服务找人"（荣耀 YOYO 建议、华为小艺 23 类记忆）；Agent 化"帮我办事了"成共识终局（OPPO："无处不在、贴心的个人超级助

理")。来源：网易；知乎 OPPO 2026。

- 【已确认】无障碍/适老化：vivo 读谱、多模态做视障人士"眼睛"导航；老年用户主动到店询问 AI 手机。来源：智东西；21 经济网。

杀手级端侧场景

- 【已确认】实时翻译/离线同传：Copilot+ Live Captions (40+ 语言离线译英)、iPhone 17 Live Translation (12 语言无网)、Gemma-3n E2B 实时语音翻译。
- 【已确认】通话实时摘要/防诈：Apple Call Screening + 语音邮件 AI 摘要；三星/Samsung 通话摘要。
- 【已确认】相册/影像本地编辑与检索：小米宠物专属影集、AI 修图本地化；HarmonyOS 6 端侧 NPU 修图 2s 启动；VLLO/Stuff 用 Apple Foundation Models 本地分析。
- 【已确认】屏幕理解与自动操作：YOYO/PhoneGPT/豆包手机跨 App 执行。
- 【已确认】本地知识问答 + 健康/敏感数据本地处理 (Jibify 金融数据本地分类不上云)。
- 来源：Microsoft；Apple newsroom；各厂商；Medium Jibify。

四、相比 2025 旧材料的关键变化点 (需更新/推翻的旧结论)

1. **参数锚点下移 + MoE 化**：端侧旗舰从"7B 为底"明确降到"3B" (Apple ~3B、vivo 3B 占 2GB 内存、Gemma-3n E2B)，同时端侧 MoE (D9500 支持、Gemma 4 26B-A4B) 让"大容量小激活"成为新范式——旧材料"投入 7B 及以下"判断需更新为"3B 当道 + MoE 抬高天花板"。
 2. **量化大幅超预期**：从旧材料"极低 bit 量化探索"推进到 **2-bit 已量产 (Apple QAT) + 1.58-bit 进芯片 (联发科 D9500 原生 BitNet 处理)**，BitNet b1.58 2B4T 证明原生 1-bit 可比肩全精度。
 3. **端侧 Agent/GUI Agent 从概念变主战场**：荣耀 MagicGUI (开源 7B + L3 认证)、vivo PhoneGPT、豆包手机秒罄——旧材料"GUI Agent 能力"已成厂商核心竞争点，但落地成功率仍低、依赖无障碍权限存隐私争议。
 4. **Apple"开放端侧 API"已兑现**：旧材料判断的"开放端侧模型 API + 上百 LoRA"已落地为 Foundation Models 框架 (WWDC25，含 LoRA/guided generation/tool calling，iOS26 量产)——从预期变既成事实。
 5. **新增"端侧推理 (reasoning)"维度**：Qwen3 hybrid thinking、DeepSeek-R1 蒸馏六款、各厂端侧 thinking 变体——旧材料未覆盖，应作为独立技术方向纳入。
 6. **端云隐私三件套成行业标配**：Apple PCC / Google Private Compute Core / 华为 HPIC——旧材料的"端云隐私方案"已从单点变行业标准。
 7. **全模态统一模型端侧化从"尝试"变"在途"**：旧材料提的 Qwen-omni 小型化已实证为 Qwen3-Omni MoE 30B-A3B (234ms 首包)、MiniCPM-o 4.5 (对标 Gemini 2.5 Flash)。
 8. **自身优势被验证且需强化**：旧材料"系统级 I/O 交互 + 端侧资源控制权 + 与芯片厂深度定制"在 2025-2026 被 OPPO (端侧计算层)、荣耀 (与高通联合低 bit 量化)、华为 (OS+芯片闭环) 反复印证——这是 OEM 相对纯模型厂/纯芯片厂的护城河，应作为战略主轴持续投入。
-

说明：因联网检索预算耗尽，以下条目未取到一手最新（2026）官方来源，已在正文标注"需复核"：Gemma 3n MatFormer 官方细节、阿里MNN/腾讯ncnn 2026 最新动态、华为手机内端侧模型确切参数/TOPS（仅有边缘板openPangu-Embedded-1B 与未官宣传闻）。建议二次提炼时补充核
验。