

2026年全球端侧AI与终端侧大模型技术前沿与竞争情报研究报告

技术趋势：端侧计算底座的重构与算法突破

端侧模型能力与规模的异构化演进

在2026年的技术周期中，端侧大模型的参数量级与架构范式经历了深刻的结构性调整。传统的密集型(Dense)端侧模型虽然在3B至7B参数区间依然保持着极高的出货量与部署率，但整体算力效率的提升已逐渐向混合专家架构(Mixture-of-Experts, MoE)倾斜¹。2026年5月发布的MobileMoE系列模型确立了端侧MoE在移动设备上的全新Pareto前沿，其通过0.3B至0.9B的活跃参数量和1.3B至5.3B的总参数量，在提供等同于密集型大模型生成精度的同时，显著降低了运行期的计算开销⁴。MobileMoE-S在INT4量化权重的显存预算下，其Prefill(首Token预填充)速度提升了1.8至3.8倍，Decode(解码)速度加快了2.2至3.4倍，展示了端侧MoE在算力与内存带宽受限设备上的优异表现⁴。

与此同时，可动态调整计算宽度的弹性模型(Elastic Models)与套娃表征(Matryoshka)技术也取

得了显著进展。通过设计类似于 m^2LLM 的弹性分块流水线(Elastic Chunk-wise Pipeline)，终端系统得以在运行期根据当前的动态内存负载与电池电量状况实时拉伸或压缩模型执行深度，从而在内存预算受限的硬件配置下实现最大化的算力输出⁶。在端侧推理(Reasoning)模型方面，MobileLLM-R1与MobileLLM-R1.5展示了在极限制约下的本地慢思考(Slow Thinking)能力，其通过在移动端CPU上直接部署高推理密度的思维链(Chain-of-Thought, CoT)，使原本极易受硬件瓶颈限制的1.5B至3B极小模型在复杂数学与代码逻辑推理指标上实现了数倍于常规模型的性能爆发²。此外，多模态端侧模型(含视觉、音频、传感器等多模态融合)已成为各大OEM厂商的核心标配，例如DeepSeek V4-Flash在激活13B参数的规模下，不仅支持高达100万Token的极限上下文，更在本地视觉理解和实时语音交互中表现出极佳的运行能效⁷。

针对物理内存远低于模型需求的超极限场景，SSD至GPU流式传输技术(Flash-MoE)打破了传统DRAM容量对端侧部署的绝对限制³。以拥有12GB内存的设备运行400B参数规模的超大型MoE模型为例，Flash-MoE利用NVMe闪存(Flash)的高速读取性能，结合窗口重用(Windowing)与行剪接捆绑(Row-column bundling)技术，使系统在生成每个Token时仅从闪存动态调入处于激活状态的2%专家参数(约4至10个专家)，在iPhone 17 Pro等物理设备上达成了0.6 Tokens/s的端侧离线推理，为小参数终端调动超大规模离线专家系统铺平了工程化道路³。

数据蒸馏与模型蒸馏的技术范式革新

2026年，利用大模型生成高质量合成数据并对端侧小模型进行多维度、深层次的蒸馏已成为模型厂商研发的核心管线。传统的Logit蒸馏(概率分布传递)与特征级(Feature-level)蒸馏技术在DeepSeek-R1等开源推理模型的催化下完成了全面升级²。通过在超大型推理大模型生成的CoT思维链数据中过滤噪音并提取高信号密度的逻辑推理轨迹，端侧小模型(1.5B至7B)在微调后获得了极强的反思与自主纠错能力，distilled 8B模型的实际数学和代码能力在多项评测中甚至超越了参数量数倍于自身的非推理基座模型²。

在训练数据配比方面，2025年底至2026年普及的AutoMixer(Meta)技术通过在预训练过程中提

取检查点人工制品(Checkpoint Artifacts)来推断最佳数据混合比,彻底取代了过去依赖昂贵消融实验的经验性调参路线²。此外,目标感知语言建模(Target-Aware Language Modeling)等粒度更为精细的采样技术,使得在数据蒸馏阶段就能够根据目标终端设备的硬件瓶颈,对高价值语料进行精准采样和上调权重,确保端侧模型在有限的参数边界内榨干每一兆字节数据的学习边际效益²。

预训练与后训练的联合优化

端侧模型的预训练与后训练流程在2026年呈现出软硬协同、对齐加速的演进方向。在小模型的有监督微调(SFT)和强化学习(RLHF/RLAIF)阶段,厂商开始广泛引入混合推理(Hybrid Thinking)训练策略,使模型在预训练语料中便植入反思和路由指令²。此外,基于设备运行状态感知的轻量级强化学习算法被直接部署在训练回环中,例如Liquid AI发布的LFM 2.5系列小模型,通过大规模、高质量的指令数据集与自适应强化学习进行联合调优,不仅在各项常识基准中取得了极为出色的表现,更在手机端动态热管理和算力分配中实现了原生级别的运行自适应性²。

量化技术的工业级重塑

量化技术在2026年迎来了颠覆性的产业落地。传统的8bit量化已被主流厂商完全抛弃,4bit和2bit混合精度量化在量产机型中已成绝对主导,而1bit/1.58bit极低比特量化也首次跨过了商用门槛¹⁰。微软提出的BitNet b1.58三值(Ternary,包含-1, 0, +1)权重表示技术,在2026年完成了从学术研究向物理设备硬加速的实质性转变¹⁰。由于QNN等主流NPU SDK原生并不支持非标准的1.58bit三值矩阵乘法,ENERZAI等团队通过利用高通Hexagon DSP的低级微码接口手写定制的1.58-bit三值乘法算子,在骁龙QCS6490等芯片上实现了BitNet 2B模型的全硬核(NPU/GPU)协同加速,在维持极低能耗的同时展现了极其紧凑的显存占用¹¹。

在量化算法上,GPTQ、AWQ、SmoothQuant等PTQ(后训练量化)方法在端侧得到了更高级的变体改造。SpinQuant(Meta)通过引入正交旋转矩阵对激活值分布进行空间重塑,在几乎无损精度的前提下消除了激活值中的离群点(Outliers),实现了权重、激活值和KV Cache整体4-bit量化损失低于3%的工程突破²。针对KV Cache这一极易在长文本推理中引爆设备显存的严重瓶颈,2026年学术界与工业界推出了多项突破性方案¹²。谷歌研究团队在ICLR 2026上提出的TurboQuant算法(PolarQuant + QJL两阶段无损压缩)成为了这一领域的行业里程碑¹²。PolarQuant首先将高维直角坐标(Cartesian)空间下的KV Cache向量转换为“极径与极角”,由于极角在角向空间中展现出高度规整的几何分布,系统可以直接对其进行极低误差的3-4 Bit量化,而极径作为标量被极小开销单独存储,从而彻底省去了逐向量归一化的元数据开销¹²。随后,TurboQuant引入仅额外占用1 Bit的Quantized Johnson-Lindenstrauss (QJL)纠偏技术,在保持向量相对投影距离不变的情况下几乎消除了量化误差,将KV Cache体积整体无损压缩至原来的五分之一(约3-4 Bit),引起了高带宽内存(HBM)相关供应链市场的剧烈震荡¹²。此外,Kitty算法通过Dynamic Channel-wise Precision Boost动态保护Key-cache中的敏感通道¹⁴,以及在CVPRW 2026上发表的“Don't Waste Bits!”自适应精度分配方案,均在物理终端上实现了近乎FP16精度的长文本对话与低发热表现¹³。

权重稀疏化、剪枝与激活稀疏

除了在量化位宽上做文章,权重稀疏化与运行期激活稀疏(Activation Sparsity)也成为了在手机上强行释放算力瓶颈的技术支柱²。SparseGPT与Wanda等结构化/非结构化剪枝方案已在端侧运行时(Runtime)中实现了原生支持²。而ProSparse、TEAL和Deja Vu等激活稀疏算法,则在模型运

行Decode时通过动态预测哪些神经元不会被激活并直接跳过其矩阵乘法计算，从而在FFN和Attention层实现了高达70%以上的动态稀疏度，使得终端设备在不削减模型纸面参数的前提下将实际运算FLOPs砍掉一大半，极大地缓解了长时间AI推理带来的电池发热降频问题²。

推理加速框架的软硬一体化调优

投机解码(Speculative Decoding)在2026年的移动SoC上经历了从“软件算法”向“存储-芯片协同系统”的硬性演进⁶。

- **Lever** 系统: 针对手机端DRAM与物理闪存(Flash)之间极其悬殊的数据读取带宽, Lever构建了高效的异步投机解码系统¹⁶。在Llama-3.1-8B等模型中, 直接从Flash读取大模型权重带来的I/O时间占据了整步推理延迟的91.4%¹⁶。Lever将极小规格的草稿模型常驻于DRAM中进行高频Token猜测, 而将大模型保留在Flash中, 仅在草稿模型积累了足够的猜测Token后才一次性调动Flash进行并行验证, 大幅平摊了高昂的Flash I/O读写损耗, 缓解了手机硬件的带宽死锁¹⁶。
- **OmniDraft** 框架: 提供了更具普适性的单草稿模型适配多目标模型在轨流式映射¹⁷。
- **SLED 与 PELM**: SLED设计了跨手机端与边缘服务器的自适应投机验证框架¹⁸。PELM(又称 *m2²LLM*) 则将投机解码算法与移动SoC的动态电压频率调节(DVFS)进行硬性闭环, 在实现最高达13.5倍TTFT加速的同时降低了24倍以上的峰值能耗⁶。

此外, 分块Prefill(Chunked Prefill)、连续批处理(Continuous Batching)以及自适应PagedAttention等长文本加速方案, 也均在2026年完成了针对移动NPU和移动GPU底层着色器的算力适配¹⁹。

模型架构的颠覆性革新

在2026年, Transformer架构在端侧的主导地位正在遭遇非注意力(Non-Attention)与混合架构(Hybrid Architectures)的强力解构²。具备线性计算复杂度的Mamba(状态空间模型/SSM)和RWKV不仅在中高阶端侧设备上达成了极速的首字生成, Qwen3系列中所引入的“Gated Delta-Net”以及DeepSeek发布的基于流形超连接(Manifold-Constrained Hyper-Connections, ManifoldHC/mHC)的改进型残差拓扑结构, 也在极深的网络层数下实现了极其优越的信号传导效率, 使得端侧模型在应对极长上下文推理时的常驻内存与瞬时FLOPs消耗呈指数级下降²。

长上下文、个性化与隐私计算技术

随着100万超大Token窗口在DeepSeek V4-Flash等端侧小模型上落地, 长上下文技术在本地面临极限制约⁷。为了防止在Prefill超大文本时导致硬件瞬间过热降频, 系统采用ExecuTorch原生支持的“滑窗注意力(Sliding-window Attention)”和块Prefill对其进行细化切片²⁰。在个性化(Personalization)方面, 通过在端侧设备上直接加载、保存并热插拔数十甚至上百个轻量级端侧LoRA适配器(Adapter), 设备学会了在本地静默微调, 学习用户的特定写作风格和交互偏好¹⁰。在最敏感的隐私保护上, 苹果的私有云计算(Public Cloud Compute, PCC)提供了云端硬件级可信执行环境(TEE)的标杆, 而华为自研的“星盾”安全架构则通过强悍的物理隔离和端云同构机制, 确保包括23类常用记忆信息、生物特征在内的最核心个人数据在本地安全沙箱内锁死, 永不上传云端, 构成了坚不可摧的本能级隐私长城²³。

端侧 Agent 的系统级贯通

2026年，端侧Agent的控制中枢已完全由传统的API/Function Calling过渡到了“视觉多模态大模型主导的屏幕理解与系统底层GUI自动操作”²⁴。阿里巴巴通义实验室于2025年底至2026年主力推行的“MAI-UI (Mobile AI User Interface)”大模型家族，基于Qwen3-VL多模态底座进行了从2B、8B到235B A22B等尺度的深度定制，不仅在Grounding(屏幕元素物理坐标精准定位)指标上横扫ScreenSpot-Pro等权威基准，更通过在系统底层深度打通Model Context Protocol(MCP)协议，使Agent能够根据当前的屏幕状态直接通过底层接口调用外部微服务²⁶。在2026年5月推出的ToolCUA模型中，研发人员引入了革命性的双阶段训练管线，通过“轨迹感知工具合成”与“在线智能体强化学习”实现了GUI屏幕点击与API直接调用的无缝Orchestration混合编排：当面对复杂的打车、购物、多步报销任务时，Agent会自主评估当前最省电、最稳定的路径——是应该像人类一样去一步步肉眼寻找、点击App按钮，还是直接在后台发起API调用或MCP工具调用，彻底打破了以往GUI智能体因长链路UI点击带来的极高耗电、极易由于界面改版而崩溃的致命死结²⁷。

专用芯片与 NPU 的能效革命

旗舰级移动SoC在2026年完成了针对多模态Prefill和极低Bit矩阵乘法的全方位的硬件硬核适配¹⁹。高通Snapdragon 8 Elite(第五代)内置的双HTP核心Hexagon NPU，在多模型并行加载和Burst(最大能效爆发)配置下表现卓越，其与LiteRT QNN加速器深度结合后，在运行FastVLM处理1024x1024高画质多维传感器输入时，达成了0.12秒的极限TTFT，Prefill吞吐率狂飙至11,000 Tokens/s，Decode速度飙升至100 Tokens/s，使本地实时的周边世界多模态监控和声纹拦截毫无延迟¹。联发科天玑9400(Dimensity 9400)搭载的APU 890，其AI运算速度飙升80%，功耗削减35%，并首次在移动端芯片硬件层直接支持On-Device LoRA Training(本地LoRA微调训练)以及天玑自研的NeuroPilot APU加速平台，为天玑大模型多模态离线50 Tokens/s的生成效率提供了近乎零功耗的物理保障²¹。

端云协同(Hybrid AI)的智能路由

2026年的端云协同完全摒弃了2025年机械的“按任务类型简单分流”策略，转向了由“用户意图模糊度、数据安全评级与网络QoS(服务质量)联合驱动的自适应智能路由”⁹。例如在MAI-UI及鸿蒙意图框架中，端侧2B或8B小模型会作为“第一守门人”，在离线状态下实时分析用户的显性或隐含意图，对其中高频、敏感的事务(约占日常操作的40%以上)直接在端侧物理沙箱内一键解决²³。只有在判定意图具有极高歧义性、需要调用海量云端网络知识库时，才会通过苹果PCC或星盾加密路由至云端大型专家模型，在提升整体系统运行性能33%的同时大幅削减了高达40%的云端昂贵模型API调用开销，在商业可行性与用户体验之间取得了完美的黄金分割²⁶。

推理框架与运行时的底座演进

由Meta在2025年底正式推出并于2026年全面铺开的ExecuTorch 1.0，已成为连接PyTorch开发环境与端侧异构SoC(Qualcomm Hexagon, Apple Neural Engine等)的最主流中继桥梁²。ExecuTorch通过精简的50KB Runtime Footprint(运行时内存常驻占用)，结合PyTorch底层的torch.compile进行AOT图级优化编译，实现了极高速度的后端委派与CPU自动降级备份，确保开发者可以在PyTorch内一键无损导出.pte文件直接跑在手机NPU上²⁰。此外，llama.cpp作为GGUF格式的底层加速支柱，在2026年完美整合了Vulkan后端着色器，使得BitNet等极低位模型

在主流GPU(Samsung S25 Adreno等)上展现出极其强悍的完全 lossless Ternary并行生成速度¹⁰。Google LiteRT与AICore则在安卓17系统底层提供了面向Gemma 3的直接多模态LLM Inference API, 极大简化了移动端App开发者在轨调用端侧算力的工程复杂度³²。

端侧模型评测基准的代际转换

在2026年, 业界对端侧小模型性能的评测彻底告别了依靠静态考卷(如MMLU、GSM8K)的传统范式, 全面转向衡量物理终端真实交互效率、抗中断性、长路径执行成功率和能耗比的系统级交互基准²⁵。

- **OSWorld** 基准: 涵盖跨操作系统Ubuntu、Windows、macOS的369个真实大型系统任务, 2026年的前沿Agent在此基准上的最好成绩已突破40%大关, 展现了极其复杂的跨软件调用与异常处理表现²⁵。
- **AndroidWorld** 基准: 专门衡量Android端离线导航能力的最高评测。通义实验室的MAI-UI在AndroidWorld上创造了76.7%的行业最高纪录, 而Mobile-Agent-v3也跑出了73.3%的优异成绩²⁵。
- **MobileWorld** 基准: 全面测试Agent在真实业务场景中, 面对模糊用户指令时的澄清(Clarification)和MCP外部API工具调用成功率, MAI-UI在此基准上达成了41.7%的商用级表现, 标志着端侧Agent正式迈入高度实用的工业阶段²⁶。

标杆厂商竞争情报分析

终端与芯片厂商的端侧AI战略格局

2026年, 终端厂商在端侧AI上的竞争呈现出系统级重组与硬件算力大灌注的激特征⁹。

厂商名称	端侧 AI 战略定位	自研/主力端侧模型(名称、参数量)	采用的核心硬加速及量化技术	典型落地的产品功能与杀手级应用	2025H2-2026最新发布会动态【已确认/预期】	端侧护城河与核心劣势分析
苹果 (Apple)	软硬高度耦合的“人机融合AIOS”生态闭环 ²²	约3B基础大模型 ²² + 动态LoRA适配器 ²²	A20 Pro ANE硬核委派 ³⁴ , 异步闪存投机解码 ¹⁶ , Apple MLX框架 ²	Siri AI(屏幕理解、standalone 历史管理) ²² 、本地Call Context ³⁶ 、自然语言Voice Control ³⁷	【已确认事实】WWDC26(2026.06): 发布iOS 27、搭载全新Siri AI, 首创离线Call Context自动抓取	护城河: 芯片-内核-应用的高度整合力, 无懈可击的私有云PCC隐私标准 ²² 。劣势: 本地模型尺寸受限 ³ 。

					邮件并多屏展示 ²² 。	
谷歌 (Google)	Android生态AIOS标准制定者与AI Agent工厂 ²⁵	Gemini Nano, Gemma 3n 移动定制版 ³²	AI Core API ³² , LiteRT QNN代理 ¹⁹ , 4-bit Groupwise ²⁰	Project Mariner Agent Studio ²⁵ 、相册与录音多模态实时长文本感知 ³²	【已确认事实】Google I/O 2026: 发布安卓17, 全面内置 Gemma 3 底层API, 主推 Mariner Studio智能体可视化生成器 ²⁵ 。	护城河: 极其庞大的安卓分发生态与前沿的开源技术底蕴。劣势: 多OEM 适配高度碎片化 ²⁵ 。
华为 (Huawei)	100%自主可控、“星盾”物理隔离的高安全硬闭环 ²³	盘古 (Pangu) 端侧优化版 ²³	星盾硬件加锁架构 ²³ , 自研 Harmony OS NEXT 微内核, 昇腾NPU	盘古赋能小艺(23类常用日常记忆、万亿Token知识、14步复杂日程、图像表格提取) ²³	【已确认事实】纯血鸿蒙 NEXT深度智变(2025-2026): 盘古大模型底层系统化, 主打核心隐私本地锁死及多模态意图框架 ²³ 。	护城河: 星盾物理安全、纯血鸿蒙底层极致流畅度 ²³ 。劣势: 国际化应用生态尚需时间迁移。
vivo	极致流畅、全 Rust内核驱动的轻量化个人助理 ⁹	蓝心多模态大模型 3B ⁹	VCAP计算加速平台 ⁹ , Rust全栈 BlueOS 3.0 ³⁸ ,	PhoneGP T ⁹ 、蓝心小V跨智能体群体协同(多 Agent群	【已确认事实】vivo 2025/2026开发者大会: 展示蓝心多	护城河: 3B模型下强悍的多模态与底层 Rust的高能效 ⁹ 。

			APU NeuroPilot	体增智) ⁹	模态大模型3B, 重点推出100% Rust重构的蓝河操作系统 ⁹ 。	劣势: 大模型云端闭环体量较弱。
小米 (Xiaomi)	覆盖“人车家”庞大物联硬件版图的端侧控制中枢 ³⁹	MiLM / 轻量级 MiMo ³⁹	超级岛系统级信息总线, 新一代权限安全开放服务 ³⁹	超级小爱 (Super Xiao AI) 系统级 AIOS 体验、多端设备协同调度 ³⁹	【已确认事实】小米2025合作伙伴大会: 推出澎湃OS 2 全新升级, 将超级小爱重塑为跨手机-车机-物联的AI总线 ³⁹ 。	护城河: 极其庞大的手机-IoT-SU7 汽车生态底座 ³⁹ 。劣势: 在极高难度算法上核心研发积累稍弱。
荣耀 (Honor)	基于视觉大模型与 Agent 反思执行的生活伙伴助理 ³³	MagicLM 极速版 ³³	蜂鸟架构 (AI滑动补轨迹、页面调度、内核轻量化) ³³	YOYO Agent 3000个自动场景14步连续系统执行 (如视觉挑甜西瓜) ³³	【已确认事实】荣耀 MagicOS 10发布: 展示系统级蜂鸟调度引擎与YOYO Agent的多感官感知反思框架 ³³ 。	护城河: YOYO对系统底层UI的高成功率点击与反思架构 ³³ 。劣势: 严重依赖第三方服务闭环。
OPPO	极致AI影像与一键交互的极速终端 ⁴⁰	AndesGPT 端侧极速版, Omni端侧全模态 ⁴⁰	联合 MediaTek APU 研发, 端侧AI补光技术 ⁴⁰	一键问屏 ⁴¹ 、一键闪记 ⁴¹ 、离线端侧AI人像光影重构 ⁴⁰	【已确认事实】Find X9系列旗舰发布(2026): 搭载全	护城河: 天玑SoC微码级联合研发, 无网AI影像重塑能

					新端侧 Omni多模态大模型，主推 AI消除和离线人像暗光重塑 ⁴⁰ 。	力行业第一 ⁴⁰ 。劣势：AIOS 系统架构重构深度相对较浅。
高通 (Qualcomm)	移动端AI 硬件底层霸主与AI Hub软件开发者生态 ¹	适配并优化上百个开源模型 ¹	骁龙8 Elite 双 HTP NPU ¹ ，FastVLM 11k tokens/s prefill ¹⁹	自研 Android NPU foreground HTTP server ¹ 、FastVLM 1024x1024 0.12s首帧描述 ¹⁹	【已确认事实】骁龙峰会与 CES 2026：展示 Snapdragon 8 Elite 多模态实录、AR眼镜环境分析极速对讲技术 ¹ 。	护城河：全球第一流的NPU 硬件算力与极高频开发者工具链 ¹ 。劣势：不对非标三值量化提供官方原生支持 ¹¹ 。
联发科 (MediaTek)	高效能 APU芯片设计者与 NeuroPilot DAE 引擎开发商 ²¹	适配并优化开源多模态/MoE ²¹	天玑9400 APU 890 ³⁰ ，10.7Gbps LPDDR5X ²¹	APU 890 DAE 离线 LoRA 训练 ²¹ 、50 Tokens/s 离线全模态生成、游戏AI语音NPC ²¹	【已确认事实】MWC 2026：推出最新 APU 890 Agent平台，展示极低毫瓦级 Always-on环境AI 及设备端 LoRA微调 ² 。	护城河：无与伦比的“全大核”CPU多线程配合高效能 APU，Always-on能效极高 ²¹ 。劣势：生态软件栈推广效率稍慢。

核心开源与端侧小模型清单及推荐部署硬件

2026年，大模型厂商不再仅仅将云端大参数模型作为拳头产品，具备极高本地推理能力和极小存储占用的开源小模型 (SLM) 已成为厂商技术实力的试金石。

- **MobileMoE-S / L (0.3B - 5.3B)**⁴：由顶级开源实验室于2026年5月推出，支持在普通智能手

机CPU/GPU上搭载自定义Fused MoE内核运行。其核心亮点在于通过适度的稀疏性与精细的专家共享架构设计，成功跨越了移动端DRAM带宽瓶颈，相比同尺寸密集型 MobileLLM-Pro，首字和解码均提速2至3倍以上⁴。

- **DeepSeek V4-Flash (13B 激活 / 284B 总参数)**⁷: 深度求索于2026年4月下旬重磅发布。该模型深度适配华为麒麟/高通骁龙旗舰移动平台，核心亮点在于**1M**超长上下文窗口，同时支持强大的本地Agentc自动执行能力，在代码及数学推理基准上几乎追平了昂贵的云端模型⁷。
- **BitNet b1.58 2B / 7B**¹⁰: 微软研究院及开源社区于2025/2026年主力推行。其可完美部署在支持Vulkan后端的移动端GPU或通过底层定制高通Hexagon DSP运行。核心亮点在于其极端的-1, 0, +1 Ternary三值权重表示，内存带宽开销锐减数倍，使得在12GB运行内存的普通手机上平稳运行13B等高阶复杂模型成为物理现实¹⁰。
- **Qwen3-A3B MoE (激活3B / 总30B)**²: 通义实验室2025年底至2026年主打的极轻量级MoE。该模型在移动端NPU及ExecuTorch 1.0框架下表现抢眼，核心亮点在于其虽仅激活3B参数，但其推理能力却超越了上一代32B级密集基座模型，是2026年移动端搭载GUI owl系统及MAI-UI实现全屏幕操作的核心底层大模型²。
- **Gemma 3n 移动版 (约3B)**³²: 谷歌于2026年上半年正式发布，完美适配高通骁龙8 Elite及谷歌Tensor旗舰处理器的LiteRT AI Edge LLM Inference API。核心亮点在于极强的本地逻辑和常识基础，支持全场景本地多模态(图像、音频、文本)并行Prefill，常驻于AICore内存中随时响应³²。

用户需求: 2026年端侧AI的痛点、典型场景与市场数据

用户价值主张的代际迁徙

在经历了第一代“云端AI助手”因高延迟、高隐私泄露风险和不断扣费带来的审美疲劳后，2026年的消费级智能终端用户在AI体验上提出了极其具体、务实的硬性需求。

本能级的隐私安全与数据主权归属(Absolute Privacy)

用户对将最核心的隐私数据(如个人银行交易原件、即时通讯聊天记录、敏感通话纪要、实时相机画面)上传至外部服务器展现出了空前的戒备与排斥，要求AI大模型必须100%在断网状态下在本地沙箱内运行，从而促成了华为“星盾”和苹果“私有云计算PCC”的大获成功¹。

真正的离线与弱网可用性(Zero Connectivity Dependency)

在地铁通勤、飞机飞行、电梯及地下车库等极易发生弱网或断网的真实物理场景下，用户抗拒AI助手瞬间“卡死”或报错，高频的离线语音导航、离线相册文字深度检索和本地应急医疗问答成为了高频刚需¹。

毫秒级极速响应与对电池寿命的零妥协(Milliseconds latency & Battery life)

云端API由于网络传输带来的来回200-500ms的物理延迟，直接摧毁了需要即时同传、AR眼镜实时视觉标注及语音管家即时打断对讲等场景的沉浸感²。用户需要低于20ms的首字生成延迟，且不接受运行AI模型后手机在半小时内发烫降频并迅速将电池电量榨干²。

终极解放: Agent化自动执行——“帮我把事办了”(Actionable Automation)

用户对纯文本Chatbot式的对话产生严重疲劳，迫切希望AI能够主动、安全且100%自动化地点击屏幕或跨App组合调用API，彻底解决繁琐的日常手工录入⁹。

2026年十大端侧 AI 杀手级应用场景分析

在上述硬性痛点驱动下，2026年消费级电子设备上爆发了十大极具商业价值的本地离线杀手级场景：

- **跨App自动报销与日常规划**：用户只需对手机说一句“帮我把昨晚拍的所有发票原件挑出来，自动录入公司钉钉报销系统，并把报销款项同步到我的本地记账软件里”。本地 2B/8B GUI Agent 自动理解屏幕，跨软件一键执行²⁶。
- **离线实时同传与深度会议纪要**：在飞机等完全无网络环境下，利用端侧多模态模型对进行中的英文商务会议进行全程、即时的语音转换，同时进行多声纹隔离和本地知识库构建²³。
- **视障人群“说你所见(Say what you see)”视觉导盲**：利用高通骁龙8 Elite等处理器的 FastVLM高画质前置传感器，视障人士只需按下手机Action按键或双击AR眼镜，本地大模型即可在0.12秒内极其详尽地描述其视野前方的所有微小障碍物、公交车牌字样及红绿灯秒数，提供细致的多步语音引导¹⁹。
- **本地隐私健康体征长期监听**：通过长期静默收集手环、智能秤、血糖监测仪等传入的本地数据，端侧模型在华为星盾硬件加锁沙箱内对其进行医学级推理，输出极其个性化的长期动态生活建议，完全杜绝健康状况外泄²³。
- **手机影像端侧光影智能重塑**：OPPO Find X9 等机型利用端侧全模态Omni模型，在暗光或逆光人像摄影中，无需联网即可对画面光线进行物理级的三维光影重构，展现出超越物理镜头硬件上限的极其自然的光影光效⁴⁰。
- **无网/弱网汽车离线语音全能管家**：在偏远自驾、超长隧道等完全无 cellular 信号覆盖的恶劣路况下，车载 Snapdragon 8 Elite NPU 依靠本地 8B Instruct 级模型平稳运行，提供毫无停顿、兼顾隐私的整车离线空调控制、大灯自适应调节及路线规划¹。
- **屏幕内容一键智能闪记与多维意图搜索**：用户通过按压系统AI按键或“一键问屏”，系统自动截取当前屏幕，在本地多模态 Omni 模型赋能下进行多轮深度图文逻辑交互，直接跨软件跨文库进行一键闪记⁴⁰。
- **智能通话反诈与本地AI换脸检测**：在用户接听视频通话或语音时，端侧模型在系统底层静默监控，利用高效能算法识别全球主流的AI伪造、AI语音合成套路，并在通话界面进行强物理拦截告警²³。
- **个性化 LoRA 适配器在轨微调**：系统在后台通过学习用户的历史微信书写习惯、常用工作汇报模板，在本地生成多套轻量LoRA Adapter，使手机在接收到日常问候或商务信息时，能主动以最符合用户个人语气、性格的书写风格自动生成 Smart Reply¹⁰。
- **视频剪辑端侧高光提取与自动字幕生成**：在本地直接调动移动端GPU，对10分钟以上的4K高画质视频进行离线的画面精彩程度自适应评分，自动剪接、添加本地无损音频，并借助本地语音大模型完成无错字自动字幕灌注²¹。

市场规模与渗透率数据

权威市场调研指出，全球通用型 AI Agent 市场在2025至2026年间正在经历极具爆发性的黄金增长期⁴³。全球月活跃用户数(MAU)预计将从2025年1月的2亿跃升至2026年12月的5.3亿，整体增幅超越一倍⁴³。而在端侧大模型重构系统微内核、推动软硬件协同方面表现最为抢眼的 GUI

Agent(屏幕自动操作智能体)细分市场, 其全球月活跃用户数(MAU)预计将从2025年1月的200万暴增至2026年12月的4,900万, 翻了近25倍⁴³。由于中国移动应用生态天然的高集成度、封闭性以及各大手机OEM厂商在系统底层推进的强力预装与软硬件定制策略, 中国在 GUI Agent 领域的全球份额占比将从29%稳步提升至36%以上, 成为全球端侧 AI 商业化下沉最彻底、消费者付费意愿最强烈的绝对核心高地⁴³。

相比2025旧材料的关键变化点

在对2025年制作的内部《业务机会点四:端侧计算》材料(包含“3B/7B端侧参数规模限制”、“极低bit量化与解码加速”、“苹果/vivo/小米/Qwen-omni等竞争情势”等论点)进行2026年最新技术在轨普查后, 可以得出以下五个维度的推翻性、修正性或重大升级的技术竞争结论:

1. 模型架构由“全密集体(Dense)”向“端侧MoE、Ternary极低Bit与流式传输”彻底迭代

- **2025年旧观点:**端侧大模型参数量死锁在3B/7B密集架构上, 受制于手机物理运行内存带宽, 部署更大规模模型在物理端侧完全不可行。
- **2026年新事实:**MobileMoE等十亿活跃、数B总参数级架构证明了端侧MoE通过“中度稀疏、专家共享”才是克服移动端DRAM带宽瓶颈的真正技术解⁴。更重要的是, BitNet b1.58(三值量化)实现了极低内存消耗下的 lossless Ternary推理, 使BitNet 2B模型仅需极小显存占用即可运行在主流NPU上, 13B高阶模型部署在移动端已被工程化攻克¹⁰; 而Flash-MoE流式传输框架更是直接向业界证明了在12GB运行内存的旗舰机上流式载入400B超大型MoE模型的可行性, 极大地拓宽了端侧 AI 的想象边界³。

2. 内存阻断壁垒由“模型权重”向“KV Cache极极限低位压缩”紧急转移

- **2025年旧观点:**端侧量化与优化的全部精力主要盯着“如何把模型权重从FP16压缩到INT4/INT8”, 以减少物理存储。
- **2026年新事实:**随着DeepSeek V4-Flash等端侧多模态小模型强力支持百万(1M)Token超长窗口, KV Cache在运行Decode时所造成的设备内存压力呈指数级飙升, 其重要性已彻底超越静态的模型权重, 成为导致手机发烫发热降频的第一罪魁祸首⁷。以谷歌TurboQuant(PolarQuant极坐标化+QJL纠偏)为代表的无损3-4 bit KV Cache压缩、Kitty动态敏感通道保护以及Don't Waste Bits自适应多精度分配, 已成为2026年长序列大模型本地部署的最核心物理防火墙, 这是2025年旧材料完全没有预见到的关键技术大拐点¹²。

3. 用户软件生态由“一问一答式的Chatbot”向“微内核底座打通的 GUI Agent”跨越

- **2025年旧观点:**端侧大模型落地主要依靠实时翻译、本地文档摘要、相册AI消除等单点独立应用, 模型本身依然是系统的“外挂工具”。
- **2026年新事实:**端侧大模型已完成了向智能操作系统核心大脑(AIOS)的底层融合⁹。用户痛点极度收敛在“跨软件、跨数据流的Agent化自动GUI屏幕操作与API混合编排”上²⁴。以苹果iOS 27 Siri AI的全局屏幕感知/Call Context、华为NEXT的盘古微内核、荣耀MagicOS 蜂鸟调度、阿里巴巴通义实验室MAI-UI(基于Qwen3-VL并支持MCP底层调用协议)和ToolCUA(双阶段强化学习)为典型代表, 大模型已被深度灌注进系统底层, 直接跨App进行视觉坐

标回归、API/MCP自适应调度,传统的“一问一答外挂对话面板”在2026年已属于落后体验²²。

4. 投机解码由“实验性软件算法”向“软硬协同的低能耗/Flash异构验证框架”硬落地

- 2025年旧观点:投机解码(Speculative Decoding)仅作为一种在服务器端加速自回归生成的通用算法被提及。
- 2026年新事实:由于手机端存在物理上的闪存与运行内存DRAM带宽不平等,投机解码成为了在物理终端克服Flash I/O死锁的唯一钥匙¹⁶。Lever(DRAM内常驻草稿模型,大幅削减高昂的Flash读取次数)、PELM(将投机解码算法与移动SoC的DVFS电压调频进行深层软硬闭环,能效比拉升24倍以上)以及SLED(跨多终端与边缘服务器自适应投机)等工程框架的商用,使得在严苛温控和电池续航硬性制约下的手机,能够平稳跑通中大参数模型,是2026年端侧大模型实现毫秒级响应的绝对工程支柱⁶。

5. 竞争局势由“各自为战”向“大模型厂商、SoC芯片商与终端OEM厂微码级共建生态”演进

- 2025年旧观点:端侧API开放给开发者,厂商独立进行芯片适配。
- 2026年新事实:端侧大模型的落地已演变为极其血腥的“大模型算法商-SoC微码内核开发者-终端OEM厂商”的三方利益深度大绑定¹¹。OPPO与联发科深度联合研发AndesGPT和端侧AI补光技术⁴⁰;ENERZAI为了跑通微软BitNet 2B直接在骁龙Hexagon DSP上用微码手写极低位算子¹¹;DeepSeek V4-Flash由华为昇腾/麒麟微内核进行物理级同构适配⁸;谷歌安卓17直接将Gemma 3系列大模型作为AICore系统服务预装常驻³²。任何不具备“芯片-系统内核-顶级大模型算法”三维闭环实力的单一终端厂商,在2026年端侧大模型技术长跑中都面临着被边缘化的巨大淘汰风险。

引用的著作

1. Running LLMs on-device with Qualcomm Snapdragon 8 Elite - Grape Up, 访问时间为 六月 24, 2026, <https://grapeup.com/blog/running-llms-on-device-with-qualcomm-snapdragon-8-elite>
2. On-Device LLMs: State of the Union, 2026 - Vikas Chandra - AI ..., 访问时间为 六月 24, 2026, <https://v-chandra.github.io/on-device-llms/>
3. iPhone 17 Pro Just Ran a 400B LLM: On-Device AI Changes Everything (2026), 访问时间为 六月 24, 2026, https://dev.to/max_quimby/iphone-17-pro-just-ran-a-400b-llm-on-device-ai-changes-everything-2026-53bm
4. [2605.27358] MobileMoE: Scaling On-Device Mixture of Experts - arXiv, 访问时间为 六月 24, 2026, <https://arxiv.org/abs/2605.27358>
5. MobileMoE: Scaling On-Device Mixture of Experts - arXiv, 访问时间为 六月 24, 2026, <https://arxiv.org/html/2605.27358v1>
6. PELM: Power Efficient On-Device LLM Inference with Speculative Decoding and

Dynamic Voltage Frequency Scaling | Request PDF - ResearchGate, 访问时间为 六月 24, 2026,

https://www.researchgate.net/publication/404694059_PELM_Power_Efficient_On-Device_LLM_Inference_with_Speculative_Decoding_and_Dynamic_Voltage_Frequency_Scaling

7. How to Use DeepSeek: Complete Guide (2026) - Tech Jacks Solutions, 访问时间为 六月 24, 2026,
<https://techjacksolutions.com/ai-tools/deepseek/how-to-use-deepseek/>
8. China's DeepSeek rolls out a long-anticipated update of its AI model - AP News, 访问时间为 六月 24, 2026,
<https://apnews.com/article/deepseek-ai-china-gpt-v4-d2ed33f2521917193616e061674d5f92>
9. 从端侧多模态到个人化智能, vivo携手开发者探索个人智能助理未来 - 品玩, 访问时间为 六月 24, 2026, <https://www.pingwest.com/a/308395>
10. LoRA Fine-Tuning BitNet b1.58 LLMs on Heterogeneous Edge GPUs via QVAC Fabric, 访问时间为 六月 24, 2026,
<https://huggingface.co/blog/qvac/fabric-llm-finetune-bitnet>
11. Running BitNet on Qualcomm Hexagon with custom 1.58 kernels ..., 访问时间为 六月 24, 2026,
<https://www.edge-ai-vision.com/2026/06/running-bitnet-on-qualcomm-hexagon-with-custom-1-58-kernels/>
12. TurboQuant in QVAC SDK 0.12.0: KV-cache quantization for ..., 访问时间为 六月 24, 2026,
<https://qvac.tether.io/blog/turboquant-in-qvac-sdk-0-12-0-kv-cache-quantization-for-production-local-ai/>
13. Don't Waste Bits! Adaptive KV-Cache Quantization for Lightweight On-Device LLMs - CVF Open Access, 访问时间为 六月 24, 2026,
https://openaccess.thecvf.com/content/CVPR2026W/LoViF/papers/Boroujeni_Don't_Waste_Bits_Adaptive_KV-Cache_Quantization_for_Lightweight_On-Device_LLMs_CVPRW_2026_paper.pdf
14. Kitty: Accurate and Efficient 2-bit KV Cache Quantization with Dynamic Channel-wise Precision Boost - arXiv, 访问时间为 六月 24, 2026,
<https://arxiv.org/pdf/2511.18643>
15. Google's TurboQuant Algorithm Compresses AI Memory Without Accuracy Loss - The Elec, 访问时间为 六月 24, 2026,
<https://www.thelec.net/news/articleView.html?idxno=6179>
16. Lever: Speculative LLM Inference on Smartphones - arXiv, 访问时间为 六月 24, 2026, <https://arxiv.org/html/2605.16786v1>
17. OmniDraft: A cross-vocabulary, online adaptive drafter for on-device speculative decoding, 访问时间为 六月 24, 2026,
<https://neurips.cc/virtual/2025/poster/118052>
18. SLED: A Speculative LLM Decoding Framework for Efficient Edge Serving | VTechWorks, 访问时间为 六月 24, 2026,
<https://vtechworks.lib.vt.edu/server/api/core/bitstreams/2ee07c93-74cc-421d-88b7-54a8607aa648/content>

19. Unlocking Peak Performance on Qualcomm NPU with LiteRT - Google Developers Blog, 访问时间为 六月 24, 2026,
<https://developers.googleblog.com/unlocking-peak-performance-on-qualcomm-npu-with-litert/>
20. ExecuTorch -- A Unified PyTorch Solution to Run AI Models On-Device - arXiv, 访问时间为 六月 24, 2026, <https://arxiv.org/pdf/2605.08195>
21. MediaTek Dimensity 9400 – Flagship 5G Agentic AI Platform, 访问时间为 六月 24, 2026, <https://www.mediatek.com/dimensity-9400>
22. Apple unveils next generation of Apple Intelligence, Siri AI, and more, 访问时间为 六月 24, 2026,
<https://www.apple.com/newsroom/2026/06/apple-unveils-next-generation-of-apple-intelligence-siri-ai-and-more/>
23. 《盘古大模型——鸿蒙NEXT的智慧引擎》- 技术专栏- Unity官方开发者社区, 访问时间为 六月 24, 2026,
<https://developer.unity.cn/projects/678234faedbc2a001dd18a2e>
24. 字节开源GUI Agent登顶GitHub热榜, 豆包手机核心技术突破26k Star - 智源社区, 访问时间为 六月 24, 2026, <https://hub.baai.ac.cn/view/52451>
25. Computer Use and GUI Agents in 2026: State of the Art | Zylus Research, 访问时间为 六月 24, 2026,
<https://zylus.ai/research/2026-02-08-computer-use-gui-agents/>
26. Alibaba's MAI-UI: The GUI Agent Revolution That's Redefining ..., 访问时间为 六月 24, 2026,
<https://medium.com/@amlgolabs/alibabas-mai-ui-the-gui-agent-revolution-that-s-redefining-mobile-ai-in-2026-96dc5810af10>
27. X-PLUG/MobileAgent: Mobile-Agent: The Powerful GUI Agent Family - GitHub, 访问时间为 六月 24, 2026, <https://github.com/x-plug/mobileagent>
28. Can AI Tap Phones and Use Computers by Itself? A Reading of the Mobile-Agent Project, 访问时间为 六月 24, 2026,
<https://knightli.com/en/2026/05/29/mobile-agent-gui-agent-family/>
29. What Is MobiAgent? An Open Source AI Agent That Can Operate Mobile Apps, 访问时间为 六月 24, 2026,
<https://knightli.com/en/2026/05/29/mobiagent-mobile-gui-agent-framework/>
30. Dimensity 9400 Vs Snapdragon 8 Elite: Gaming And AI Faceoff 2026 | Cashify Blog, 访问时间为 六月 24, 2026,
<https://www.cashify.in/mediatek-dimensity-9400-vs-snapdragon-8-elite>
31. Intro to LLMs in ExecuTorch - PyTorch documentation, 访问时间为 六月 24, 2026,
<https://docs.pytorch.org/executorch/0.5/llm/getting-started.html>
32. On-device LLM inference on Android - Grokipedia, 访问时间为 六月 24, 2026,
https://grokipedia.com/page/On-device_LLM_inference_on_Android
33. 科氮| 荣耀MagicOS 10重构智能体验: AI成伙伴, 全品牌互联破冰 - 新浪财经, 访问时间为 六月 24, 2026,
<https://finance.sina.com.cn/stock/t/2025-10-25/doc-infvceug1912288.shtml>
34. Apple's Next Releases: 20 New Devices Coming in 2026 and 2027, 访问时间为 六月 24, 2026,
<https://www.macobserver.com/news/apples-next-releases-20-new-devices-com>

[ing-in-2026-and-2027/](#)

35. Apple Seeds iOS 27 and iPadOS 27 Second Betas to Developers, 访问时间为 六月 24, 2026, <https://www.macrumors.com/2026/06/22/apple-seeds-ios-27-beta-2/>
36. Apple Intelligence brings powerful AI capabilities into everyday experiences, 访问时间为 六月 24, 2026, <https://www.apple.com/newsroom/2026/06/apple-intelligence-brings-powerful-ai-capabilities-into-everyday-experiences/>
37. Apple unveils new accessibility features, and updates with Apple Intelligence, 访问时间为 六月 24, 2026, <https://www.apple.com/newsroom/2026/05/apple-unveils-new-accessibility-features-and-updates-with-apple-intelligence/>
38. 2025 vivo开发者大会: 自研蓝河操作系统3正式发布, 访问时间为 六月 24, 2026, <https://developers.vivo.com/activity/details?id=95>
39. 2025 小米人车家全生态合作伙伴大会, 访问时间为 六月 24, 2026, <https://dev.mi.com/partnersconference/2025>
40. OPPO 与联发科技于MWC 2026 深化端侧AI 合作, 展示移动智能新成果, 访问时间为 六月 24, 2026, <https://www.oppo.com/cn/newsroom/press/545/>
41. OPPO 亮相2025 世界人工智能大会, 刷新端侧AI 性能上限, 访问时间为 六月 24, 2026, <https://www.oppo.com/cn/newsroom/press/538/>
42. 2025年旗舰机端侧大模型能力深度评测 - 新浪财经, 访问时间为 六月 24, 2026, <https://cj.sina.cn/articles/view/7879848900/1d5acf3c401902xsim?froms=ggmp&vt=4>
43. 2026年中国智能体市场洞察- 侵入式Agent产业治理白皮书, 访问时间为 六月 24, 2026, https://pdf.dfcfw.com/pdf/H3_AP202603261820773453_1.pdf?1774554389000.pdf